Duomenų analizės įvadas

2.2. dalis - R programavimas

Justas Mundeikis

VU EVAF

2019-04-08

Turinys

Loop funkcijos

Loop funkcijos

Rašant skriptus, `for`, `while` ir kiti loopai yra tinkami, bet jeigu norima parašyti kodą tiesiog konsolėje, tada susiduriama su daug problemų.

- `lapply`: loopina per list ir paleidžia funkciją kiekvienam elementui
- `sapply`: veikia kaip ir `lapply` tik supaprastina rezultatus
- `apply`: taiko funkciją masyvo stulepliams / eilutėms
- `tapply`: taiko funkciją vektoriaus dalims
- `mapply`: multivariatinė `lapply` versija

apply

apply

`apply` naudojama taikyti funkcijas dataframe, matricų eilutėms ar stulpeliams. `apply` iš esmės supaprastina `for loop` naudojimą.

```
args(apply)
## function (X, MARGIN, FUN, ...)
## NULL
# kur X yra array
# MARGIN=1 eilutėms
# MARGIN=2 stulpeliams
# FUN taikoma funkcija
```

apply

```
x <- matrix(1:4,2,2)
x
##      [,1] [,2]
## [1,]    1    3
## [2,]    2    4
apply(x, 1, mean) # 1 - eiltuėms
## [1] 2 3
apply(x, 2, mean) # 2 - stulpeliams
## [1] 1.5 3.5
apply(x, 1, sum) # 1 - eiltuėms
## [1] 4 6
apply(x, 2, sum) # 2 - stulpeliams
## [1] 3 7
```

apply

Norint pritaikyti apply funkciją daugiau dimensijų turinčiam duomenų masyvui, būtina nurodyti vektorių, kurios dimensijos išlaikomos

```
x <- array(data=rnorm(40), dim = c(2,2,10))
apply(x, c(1,2), mean) # išlaikoma 1 ir 2 dimensijos
##             [,1]      [,2]
## [1,] -0.2259078 0.3731778
## [2,]  0.3219029 0.1585779
```

apply

Exercise:

- create a sales dataframe
- calculate sales
  - for every month
  - for every sales person

```
#generate sales dataframe
set.seed(101)
sales <- data.frame(row.names = month.abb[1:12],
                    Marry=sample(0:100,12, replace = TRUE),
                    John=sample(100:200,12, replace = TRUE),
                    Felix=sample(150:300,12, replace = TRUE),
                    Jenny=sample(0:400,12, replace = TRUE))
```

apply

Solution:

```
## Jan Feb Mar Apr May Jun Jul Aug Sep Oct Nov Dec
## 581 794 384 803 592 578 718 467 569 518 466 890
## Marry  John Felix Jenny
##   601  1872  2667  2220
```

apply

Build follwing graphs:

* line chart with dots for monthly sales
* bar chart for every sales person's yearly turnover
* boxplot for every sales person's monthly sales

Solutions should look like:

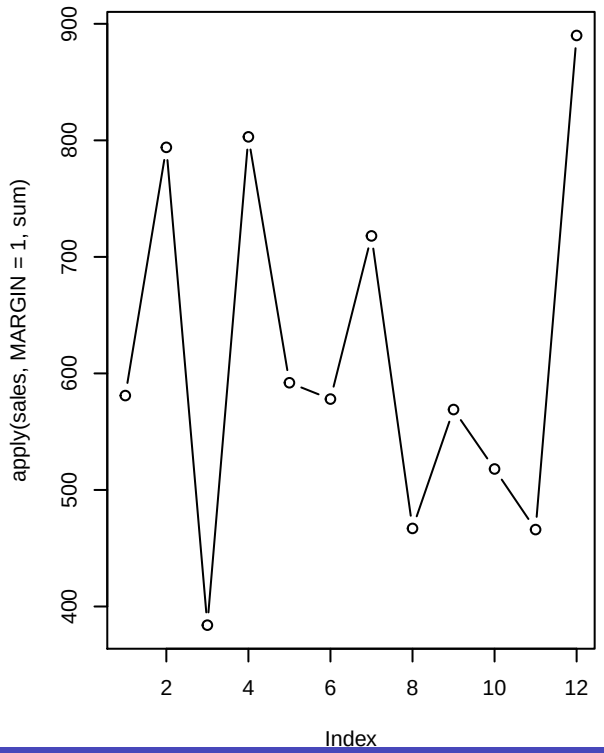

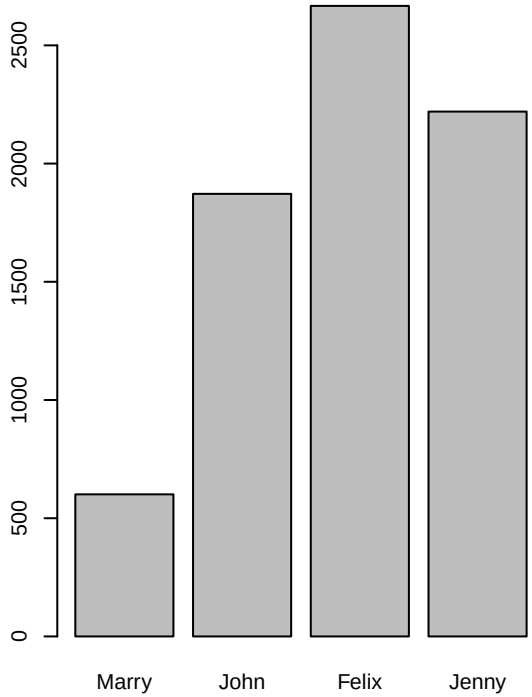

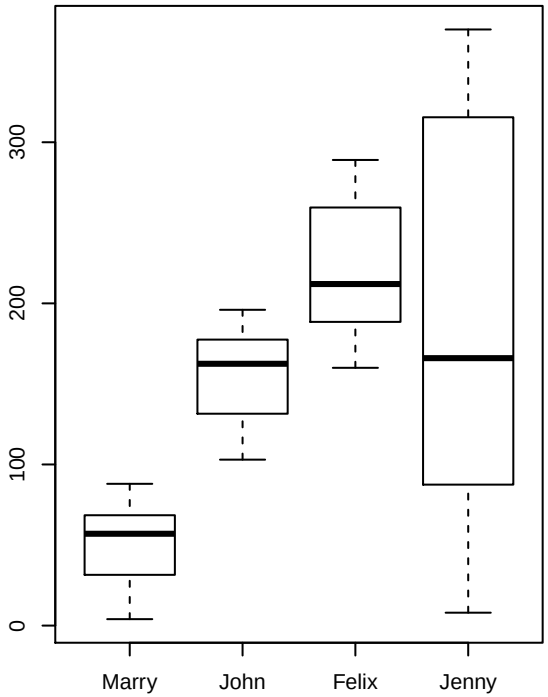

apply

Jeigu norima apskaičiuoti dataframe / matricų eilučių ar stuleplių sumas / vidurkius, galima naudoti jau supaprastintas funkcijas, jos veikia dar greičiau, nes yra parašytas su c++, tačiau skirtumas pasijaučia tik su labai dideliais duomenų masyvais.

- `rowSums=apply(x,1,sum)`
- `rowMeans=apply(x,1,mean)`
- `colSums=apply(x,2,sum)`
- `colMeans=apply(x,2,mean)`

apply

`apply` priima `...` taigi galima deleguoti papildomus funkcijų parametrus. PVZ:

- `quantile`: The generic function quantile produces sample quantiles corresponding to the given probabilities. The smallest observation corresponds to a probability of 0 and the largest to a probability of 1.
- `summary`: summary is a generic function used to produce result summaries of the results of various model fitting functions. The function invokes particular methods which depend on the class of the first argument.

apply

```
args(apply)
## function (X, MARGIN, FUN, ...)
## NULL
# for ... arguments of quantile function
apply(sales, 2, quantile, probs=c(0,0.25 ,0.5, 0.75,1))
##      Marry   John  Felix  Jenny
## 0%    4.00 103.00 160.00   8.00
## 25%  32.25 136.25 193.25  90.25
## 50%  57.00 162.50 212.00 166.00
## 75%  67.25 175.25 254.25 310.25
## 100% 88.00 196.00 289.00 370.00
apply(sales, 2, summary, digits=0)
##         Marry John Felix Jenny
## Min.        4  100   200     8
## 1st Qu.    30  100   200    90
## Median     60  200   200   200
## Mean       50  200   200   200
## 3rd Qu.    70  200   300   300
## Max.       90  200   300   400
```

rep

rep

- `rep` - Replicate Elements of Vectors and Lists
- `rep` - replicates the values in `x`. It is a generic function, and the (internal) default method is described here.

```
args(rep)
## function (x, ...)
## NULL
rep(c("a","b"), c(1,3))
## [1] "a" "b" "b" "b"
```

sweep

sweep

Return an array obtained from an input array by sweeping out a summary statistic.

```
args(sweep)
## function (x, MARGIN, STATS, FUN = "-", check.margin = TRUE, ...)
## NULL
```

sweep

- Kartais reikia naudotis normalizuotais duomenimis
- $z = \frac{X - \mu}{\sigma}$

PVZ:

```
sales_mean <- apply(sales, 2, mean)
sales_sd <- apply(sales, 2, sd)
df1 <- sweep(sales, 2, sales_mean, "-")
df2 <- sweep(df1, 2, sales_sd, "/")
```

sweep

```
par(mfrow=c(1,2))
boxplot(sales)
boxplot(df2)
```

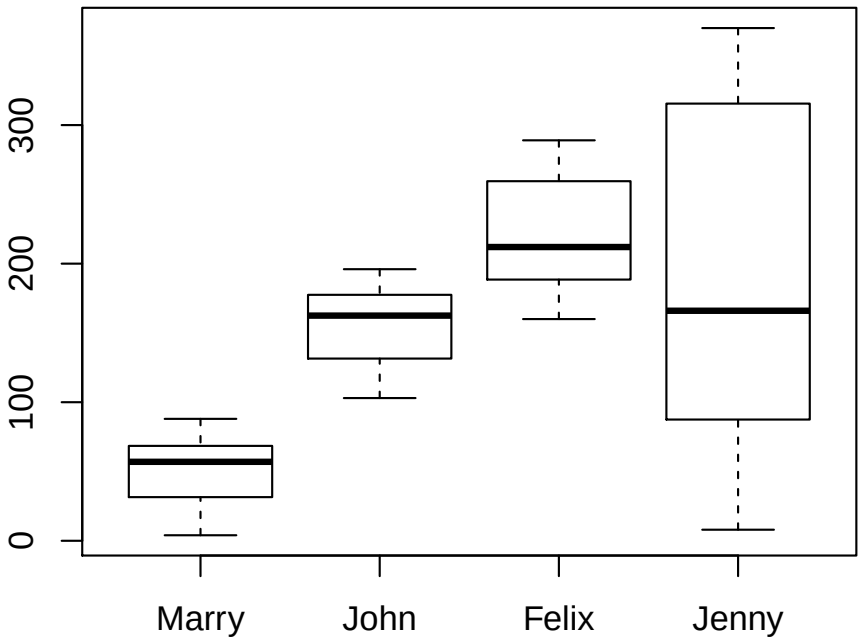

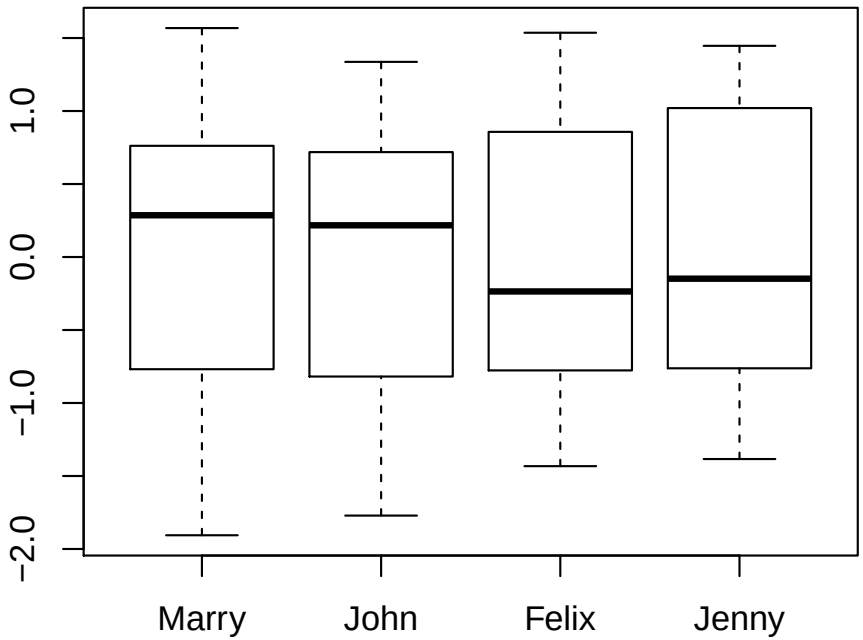

lapply

lapply

`lapply` priima 3 argumentus:

1. list objektą,
2. funkciją arba funkcijos pavadinimą,
3. galimus funkcijos papildomus argumentus

Jeigu `X` nėra list, tada R bando paversti `X` list objektu.

```
args(lapply)
## function (X, FUN, ...)
## NULL
```

lapply

`lapply` visad grąžina `list` klasės objektą

```
set.seed(101)
x <-  list(a=1:10,
           b=rnorm(50),
           c=seq(from=100, to=200, by=2))
lapply(x, mean)
## $a
## [1] 5.5
##
## $b
## [1] -0.1239708
##
## $c
## [1] 150
```

lapply

```
y <- 1:3
as.list(1:3) #taip lapply mato vektorių x konvertuus jį į list objektą
## [[1]]
## [1] 1
##
## [[2]]
## [1] 2
##
## [[3]]
## [1] 3
```

lapply

```
lapply(y, runif)
## [[1]]
## [1] 0.1250194
##
## [[2]]
## [1] 0.02332669 0.39186128
##
## [[3]]
## [1] 0.8595986 0.7183345 0.3393950
```

lapply

Išnaudojant `...` galime perleisti papildomus argumentus `runif` funckijai:

```
x <- 1:3
lapply(x, runif, min=5, max=10)
## [[1]]
## [1] 5.406107
##
## [[2]]
## [1] 5.186172 8.865444
##
## [[3]]
## [1] 9.975411 5.732932 5.199224
```

lapply

`lapply` ir kitos apply funkcijos gali naudotis `USER DEFINED FUNCTION`, t.y. niekur kitur nedefinuotomis funkcijomis

```
z <- list(a=matrix(1:9, nrow=3, ncol = 3),
          b=matrix(1:4, nrow = 2, ncol=2))
lapply(z, function(elt) elt[,1, drop=FALSE]) #elt yra anoniminė funkcija
## $a
##      [,1]
## [1,]    1
## [2,]    2
## [3,]    3
##
## $b
##      [,1]
## [1,]    1
## [2,]    2
```

lapply

Klausimas: ką generuoja ši `lapply` funkcija?

```
set.seed(101)
A <- matrix(sample(1:10,9),3,3)
B <- matrix(sample(1:10,9),3,3)
C <- matrix(sample(1:10,9),3,3)
MAT_LIST <- list(A,B,C)

lapply(MAT_LIST, "[", ,1)
## [[1]]
## [1] 4 1 6
##
## [[2]]
## [1]  6  8 10
##
## [[3]]
## [1] 5 1 6
```

lapply

Exercise: Use `lapply` to calculate sales for every sales-person

Solution:

```
## $Marry
## [1] 601
##
## $John
## [1] 1872
##
## $Felix
## [1] 2667
##
## $Jenny
## [1] 2220
```

sapply

sapply

`sapply` bando supaprastinti `lapply` rezultatus (jeigu įmanoma)

- jeigu `lapply` grąžintų list, kurių kiekvienas elementas yra 1 ilgumo, tada `sapply` grąžina vektorių
- jeigu `lapply` grąžintų list, kurių kiekvienas elementas yra >1 ir vienodo ilgumo, tada `sapply` grąžina matricą
- jeigu netinka pirma du variantai, grąžina list

sapply

```
set.seed(101)
x <-  list(a=1:10,
           b=rnorm(50),
           c=seq(from=100, to=200, by=2))
lapply(x, mean)
## $a
## [1] 5.5
##
## $b
## [1] -0.1239708
##
## $c
## [1] 150
```

sapply

```
set.seed(101)
x <-  list(a=1:10,
           b=rnorm(50),
           c=seq(from=100, to=200, by=2))
sapply(x, mean)
##           a           b           c
##   5.5000000  -0.1239708 150.0000000
```

sapply

```
sapply(MAT_LIST,"[",1,1, simplify = TRUE)  # nepriima tuščių argumentų
## [1] 4 6 5
sapply(MAT_LIST,"[",1,1, simplify = FALSE) # nepriima tuščių argumentų
## [[1]]
## [1] 4
##
## [[2]]
## [1] 6
##
## [[3]]
## [1] 5
```

sapply

Exercise: Use `sapply` to calculate sales for every sales-person

Solution:

```
## Marry  John Felix Jenny
##   601  1872  2667  2220
```

mapply

mapply

- `mapply` taiko paraleliai (vienu metu) funckiją skirtingiems argumentams naudojantis list arba vektoriais
- m - multivariate

```
str(mapply)
## function (FUN, ..., MoreArgs = NULL, SIMPLIFY = TRUE, USE.NAMES = TRUE)
```

- `FUN` yra funkcija, kuri bus taikoma
- `...` argumentai, kuriais naudojamasi funkcijoje
- `MoreArgs` kiti `FUN` argumentai
- `SIMPLIFY` ar rezultatas turėtų būti simplifikuotas kaip `sapply`

mapply

Jeigu norime sukurti tokį list objektą, 4 kartus rašome rep(), su argumentais 1-4 ir 4-1

```
list(rep(1,4), rep(2,3), rep(3,2), rep(4,1))
## [[1]]
## [1] 1 1 1 1
##
## [[2]]
## [1] 2 2 2
##
## [[3]]
## [1] 3 3
##
## [[4]]
## [1] 4
```

mapply

Supaprastinant galima naudoti `mapply` funkciją, kurios argumentai `rep` funckija ir du vektoriai 1:4 ir 4:1

```
mapply(rep, 1:4, 4:1)
## [[1]]
## [1] 1 1 1 1
##
## [[2]]
## [1] 2 2 2
##
## [[3]]
## [1] 3 3
##
## [[4]]
## [1] 4
```

mapply

Funkcija `noise` generuoja `n` atsitiktinių normaliojo skirstinio skaičių su vidurkiu `mean` ir standartiniu nuokrypiu `sd`

```
noise <- function(n, mean, sd){
        rnorm(n, mean, sd)
}

noise(4,1,2) # veikia kaip tikėtasi
## [1] -1.3005106  0.4510577  2.1558020 -1.7938053
# list(noise(1,1,0.1),noise(2,2,0.1),noise(3,3,0.1),noise(4,4,0.1))
noise(1:4,1:4,0.01) # veikia ne kaip tikėtasi
## [1] 1.007491 1.989488 3.001654 4.011298
```

mapply

Šioje vietoje galima naudotis `mapply` tam, kad funkcija priimtų argumentus iš vektorių

```
noise <- function(n, mean, sd){
        rnorm(n, mean, sd)
}
# dabar norime generuoti tokį list objektą
# list(noise(1,1,0.1),noise(2,2,0.1),noise(3,3,0.1),noise(4,4,0.1))
mapply(noise, 1:4, 1:4, 0.01)
## [[1]]
## [1] 1.011737
##
## [[2]]
## [1] 1.995721 1.997402
##
## [[3]]
## [1] 2.985888 2.993586 3.001125
##
## [[4]]
## [1] 4.004226 4.003868 3.993122 4.001489
```

mapply

Exercise:

- Generate following matrix using `mapply`

```
##      [,1] [,2] [,3] [,4] [,5]
## [1,]    1    2    3    4    5
## [2,]    1    2    3    4    5
## [3,]    1    2    3    4    5
## [4,]    1    2    3    4    5
## [5,]    1    2    3    4    5
```

rapply

rapply

`rapply` yra *recursive apply* ir taikomas `list` objektams

```
args(rapply)
## function (object, f, classes = "ANY", deflt = NULL, how = c("unlist",
##     "replace", "list"), ...)
## NULL

# PVZ:
z <- list(1,2,3,4)
rapply(z, function(x){x^2})
## [1]  1  4  9 16
```

rapply

Exercise:

- Calculate the bonus for each salesperson
- Bonus =0.15 * average sales of the year (use `rapply` and either `lapply` or `sapply`)

```
##   Marry    John   Felix   Jenny
##  7.5125 23.4000 33.3375 27.7500
##   Marry    John   Felix   Jenny
##  7.5125 23.4000 33.3375 27.7500
##   Marry    John   Felix   Jenny
##  7.5125 23.4000 33.3375 27.7500
##   Marry    John   Felix   Jenny
##  7.5125 23.4000 33.3375 27.7500
```

rapply

Papildomi `rapply` pvz., savistudijoms
https://www.r-bloggers.com/rapply-function-explanation-and-examples

tapply

tapply

Apply a function to each cell of a ragged array, that is to each (non-empty) group of values given by a unique combination of the levels of certain factors.

```
str(tapply)
## function (X, INDEX, FUN = NULL, ..., default = NA, simplify = TRUE)
```

- `X` yra vektorius
- `INDEX` faktorius arba faktorių list
- `FUN` taikoma funkcija
- `...` papildomi `FUN` argumentai
- `simplify` ar supaprastinti rezultatus

tapply

```
set.seed(101)
x <- c(rnorm(10), runif(10, min=5, max=15), rnorm(10, mean = 100))
x
##  [1]  -0.3260365   0.5524619  -0.6749438   0.2143595   0.3107692
##  [6]   1.1739663   0.6187899  -0.1127343   0.9170283  -0.2232594
## [11]  12.0071155  14.5683746   7.1335200  11.6106150  14.2331888
## [16]  12.9571976   5.7121255   8.8940777   9.0645122  11.5935508
## [21]  99.8066620  99.1502453 100.0584655  99.1823296  97.9496922
## [26]  99.8362443 100.7085221  99.7320195  98.5360782 100.7444358
# Generate factors by specifying the pattern of their levels.
#gl(n, k, length = n*k, labels = seq_len(n), ordered = FALSE)
f <- gl(3,10)
f
##  [1] 1 1 1 1 1 1 1 1 1 1 2 2 2 2 2 2 2 2 2 2 3 3 3 3 3 3 3 3 3 3
## Levels: 1 2 3
```

tapply

Supjaustome `x` vektorių pagal faktorių vektorių `f` ir pritaikome `mean`

```
tapply(x, f, mean)
##          1          2          3
##  0.2450401 10.7774278 99.5704695
tapply(x, f, mean, simplify = FALSE)
## $`1`
## [1] 0.2450401
##
## $`2`
## [1] 10.77743
##
## $`3`
## [1] 99.57047
```

tapply

Supjaustome `x` vektorių pagal faktorių vektorių `f` ir pritaikome `summary`

```
tapply(x, f, summary)
## $`1`
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## -0.6749 -0.1956  0.2626  0.2450  0.6022  1.1740
##
## $`2`
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   5.712   8.937  11.602  10.777  12.720  14.568
##
## $`3`
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   97.95   99.16   99.77   99.57  100.00  100.74
```

split

split

`split` padalina vektorių arba kitą objektą į grupes priklausomai nuo faktorių arba faktorių list

```
str(split)
## function (x, f, drop = FALSE, ...)
```

- `x` vektorius / list / dataframe
- `f` faktorius arba faktorių list
- `drop` indikuoja, ar tušti faktoriai turėtų būti panaikinti

split

```
split(x, f)
## $`1`
##  [1] -0.3260365  0.5524619 -0.6749438  0.2143595  0.3107692  1.1739663
##  [7]  0.6187899 -0.1127343  0.9170283 -0.2232594
##
## $`2`
##  [1] 12.007115 14.568375  7.133520 11.610615 14.233189 12.957198  5.7121
##  [8]  8.894078  9.064512 11.593551
##
## $`3`
##  [1]  99.80666  99.15025 100.05847  99.18233  97.94969  99.83624 100.708
##  [8]  99.73202  98.53608 100.74444
# dabar galima naudoti lapply / sapply
```

split

Taigi galime suskaidyti `x` į 3 `list` objektus ir tada kiekvienam atlikti `lapply` arba

```
lapply(split(x, f),mean)
## $`1`
## [1] 0.2450401
##
## $`2`
## [1] 10.77743
##
## $`3`
## [1] 99.57047
tapply(x, f, mean)
##          1          2          3
##  0.2450401 10.7774278 99.5704695
```

split

- Pasitikriname ar loadina `airquality` dataset, jeigu ne `library(datasets)`
- Mūsų tikslas: apskaičiuoti 4 kintamųjų vidurkius: Ozone, Solar.R, Wind, Temp

```
head(airquality)
##   Ozone Solar.R Wind Temp Month Day
## 1    41     190  7.4   67     5   1
## 2    36     118  8.0   72     5   2
## 3    12     149 12.6   74     5   3
## 4    18     313 11.5   62     5   4
## 5    NA      NA 14.3   56     5   5
## 6    28      NA 14.9   66     5   6
```

split

Supjaustome `airquality` pagal mėnesius:

```
s <- split(airquality, airquality$Month)
```

split

- Pritaikome `lapply` funckiją.
- Ką reikia pakeisti, jog negauti mėnesių ir dienų vidurkių, bei panaikinti `NA`?

```
lapply(s, function(x) colMeans(x))
## $`5`
##    Ozone  Solar.R     Wind     Temp    Month      Day
##       NA       NA 11.62258 65.54839  5.00000 16.00000
##
## $`6`
##     Ozone   Solar.R      Wind      Temp     Month       Day
##        NA 190.16667  10.26667  79.10000   6.00000  15.50000
##
## $`7`
##      Ozone    Solar.R       Wind       Temp      Month        Day
##         NA 216.483871   8.941935  83.903226   7.000000  16.000000
##
## $`8`
##     Ozone   Solar.R      Wind      Temp     Month       Day
##        NA        NA 8.793548 83.967742  8.000000 16.000000
```

split

Solution:

```
## $`5`
##     Ozone   Solar.R      Wind      Temp
##  23.61538 181.29630  11.62258  65.54839
##
## $`6`
##     Ozone   Solar.R      Wind      Temp
##  29.44444 190.16667  10.26667  79.10000
##
## $`7`
##      Ozone    Solar.R       Wind       Temp
##  59.115385 216.483871   8.941935  83.903226
##
## $`8`
##      Ozone    Solar.R       Wind       Temp
##  59.961538 171.857143   8.793548  83.967742
##
## $`9`
##     Ozone   Solar.R      Wind      Temp
```

split

su `sapply`:

```
##                5         6         7         8         9
## Ozone     23.61538  29.44444  59.115385  59.961538  31.44828
## Solar.R 181.29630 190.16667 216.483871 171.857143 167.43333
## Wind      11.62258  10.26667   8.941935   8.793548  10.18000
## Temp      65.54839  79.10000  83.903226  83.967742  76.90000
```

split

Importuojame į R tikrus Lietuvos darbo užmokesčio duomenis:

```
url <- "/home/pc/Dropbox/UNI/Teaching/VU/duomenu_analizes_ivadas/lectures_s
df <- read.csv(url)
head(df,5)
##   Laikotarpis                          Rodiklis Tipas            Lytis
## 1        1995 Darbo užmokestis (mėnesinis) Bruto Vyrai ir moterys
## 2        1995 Darbo užmokestis (mėnesinis) Bruto Vyrai ir moterys
## 3        1995 Darbo užmokestis (mėnesinis) Bruto Vyrai ir moterys
## 4        1995 Darbo užmokestis (mėnesinis) Bruto             Vyrai
## 5        1995 Darbo užmokestis (mėnesinis) Bruto             Vyrai
##                                                 Sektorius Matavimo.vienetai
## 1          Šalies ūkis su individualiosiomis įmonėmis                 EUR
## 2                                Viešasis sektorius                 EUR
## 3 Privatusis sektorius su individualiosiomis įmonėmis                 EUR
## 4          Šalies ūkis su individualiosiomis įmonėmis                 EUR
## 5                                Viešasis sektorius                 EUR
##   Reikšmė
## 1   139.3
## 2   153.9
```

split

- Supjaustom `df` pagal `Lytis` ir `Sektorius`
- Inspektuojam gautą objektą

```
df_s <- split(df, list(df$Lytis, df$Sektorius))
```

split

Apskaičiuojamepajamų vidurkius

```
sapply(df_s, function(x) mean(x[,"Reikšmė"], na.rm=TRUE))
##          Moterys.Privatusis sektorius su individualiosiomis įmonėmis
##                                                              572.7300
##            Vyrai.Privatusis sektorius su individualiosiomis įmonėmis
##                                                              693.2500
## Vyrai ir moterys.Privatusis sektorius su individualiosiomis įmonėmis
##                                                              436.1522
##                   Moterys.Šalies ūkis su individualiosiomis įmonėmis
##                                                              613.1300
##                     Vyrai.Šalies ūkis su individualiosiomis įmonėmis
##                                                              720.8800
##          Vyrai ir moterys.Šalies ūkis su individualiosiomis įmonėmis
##                                                              460.0391
##                                                 Moterys.Viešasis sektorius
##                                                              663.2300
##                                                   Vyrai.Viešasis sektorius
##                                                              801.8000
##                                        Vyrai ir moterys.Viešasis sektorius
```

aggregate

agregate

Splits the data into subsets, computes summary statistics for each, and returns the result in a convenient form.

```
args(aggregate)
## function (x, ...)
## NULL
?aggregate
```

- x - an R object.
- by- a list of grouping elements, each as long as the variables in the data frame x. The elements are coerced to factors before use.

agregate

```
aggregate(airquality,
          list(airquality$Month), #jeigu nebus list() mes klaid, nes tada b
          mean, na.rm=TRUE)
##   Group.1    Ozone  Solar.R      Wind     Temp Month  Day
## 1       5 23.61538 181.2963 11.622581 65.54839     5 16.0
## 2       6 29.44444 190.1667 10.266667 79.10000     6 15.5
## 3       7 59.11538 216.4839  8.941935 83.90323     7 16.0
## 4       8 59.96154 171.8571  8.793548 83.96774     8 16.0
## 5       9 31.44828 167.4333 10.180000 76.90000     9 15.5
# tik vienam kintamajam
aggregate(airquality$Ozone, list(airquality$Month), FUN=mean, na.rm=TRUE)
##   Group.1        x
## 1       5 23.61538
## 2       6 29.44444
## 3       7 59.11538
## 4       8 59.96154
## 5       9 31.44828
```

agregate

Exercise:

- pritaikykite aggregate norint apskaičiuoti vidutines mėnesines pajamas
- pastaba: galima pasirinkti tik norimą stulpelį

```
##                Lytis                                                Sektorius
## 1            Moterys Privatusis sektorius su individualiosiomis įmonėmis
## 2              Vyrai Privatusis sektorius su individualiosiomis įmonėmis
## 3 Vyrai ir moterys Privatusis sektorius su individualiosiomis įmonėmis
## 4            Moterys          Šalies ūkis su individualiosiomis įmonėmis
## 5              Vyrai          Šalies ūkis su individualiosiomis įmonėmis
## 6 Vyrai ir moterys          Šalies ūkis su individualiosiomis įmonėmis
## 7            Moterys                                  Viešasis sektorius
## 8              Vyrai                                  Viešasis sektorius
## 9 Vyrai ir moterys                                  Viešasis sektorius
##           x
## 1 572.7300
## 2 693.2500
## 3 436.1500
```

Distribucijos

Distribucijos

Ne retai atliekant įvarius tyrimus ar skaičiuojant tikimybes statistikoje, reikės remtis tam tikrais skirstiniais. R gali generuoti įvarius skirstinius (*distributions*)

```
?distributions
```

- dnorm
- dgamma
- beta
- dpois

ir t.t.

Distribucijos

Šioje dalyje aptarsime

- Binomial Distribution
- Poisson Distribution
- Continuous Uniform Distribution
- Exponential Distribution
- Normal Distribution

Distribucijos

Visos distribucijos galimos su 4 funkcijomis:

```
# ?dnorm

dnorm(x, mean = 0, sd = 1, log = FALSE)
pnorm(q, mean = 0, sd = 1, lower.tail = TRUE, log.p = FALSE)
qnorm(p, mean = 0, sd = 1, lower.tail = TRUE, log.p = FALSE)
rnorm(n, mean = 0, sd = 1)
```

- d density
- p cumulative distribution
- q quantile function
- r random number generation

Binominis skirstinys

Binominis skirstinys

Dichotomine matavimų skale matuojamų požymių reikšmių skirstinys (0/1, herbas/skaičius, moteris/vyras, išlaikė/neišlaikė)

Skirstinys yra diskretus ir apibūdinamas parametrais n ir p. Parametras $n \geq 0$ reiškia bandymų skaičių, o p – požymio tikimybę įgyti vieną iš dviejų galimų reikšmių.

Binominio skirstinio pasiskirstymo tankio funkcija (tikimybė gauti x reikmšę su n bandymų ir p tikimybės reikmše):

$$f(x) = \binom{n}{x} p^x (1-p)^{n-x} \text{ kur } x = 1, 2, 3, ..., n$$

Binominis skirstinys

Tarkime duomenų analizės teste yra 10 klausimų, kurių kiekvienas turi 4 galimus atsakymus, iš kurių tik vienas yra teisingas. Tarkime studentas atėjo visiškai nepasiruošęs ir visiškai atsitiktinai pasirinks atsakymus. Norint išlaikyti testą, reikia teisingai astakyti į ne mažiau kaip 5 klausimus. Kokia tikimybė, jog studentas neišlaikys testo?

- p = 1/4=0.25 ir (1-p)=1-0.25=0.75
- n = 10
- x=4

Diskreti tikimybė:

```
# tikimybė jog studentas atsakys lygiai 4 teisingai
dbinom(x=4, size = 10, prob = 0.25)
## [1] 0.145998
```

Binominis skirstinys

```
x <- seq(from=0, to=10, by=1)
y <- dbinom(x, size=10, prob=0.25)
plot(x,y, type = "b")
axis(side = 1, at = x,labels = T)
```

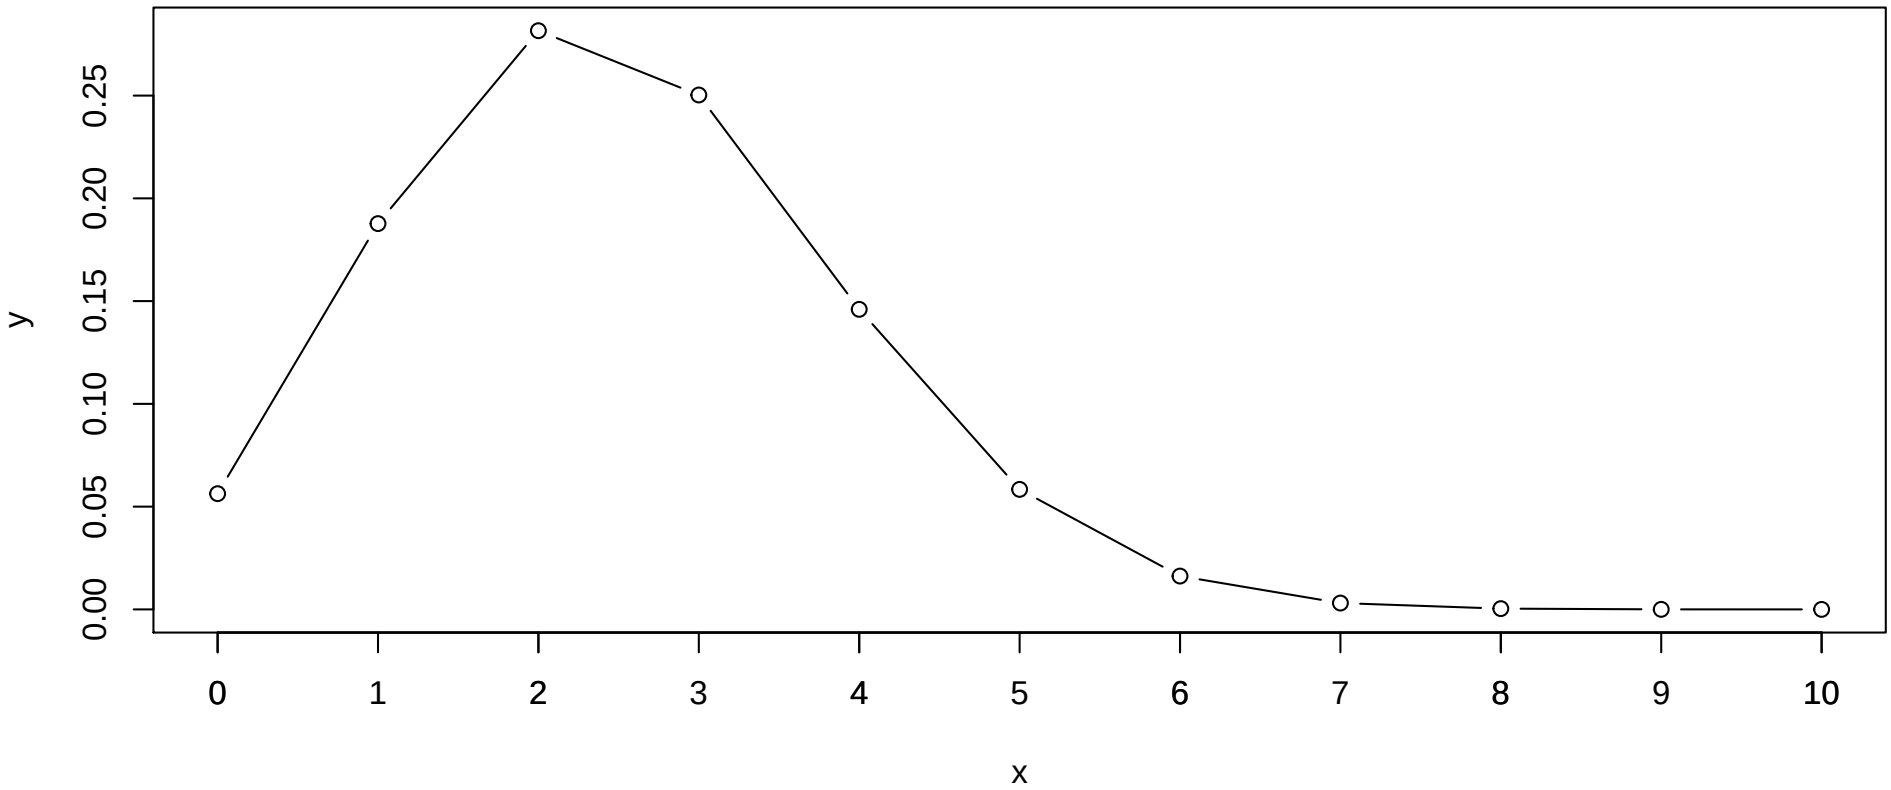

Binominis skirstinys

Tačiau norint žinoti visas vertes iki 4

```
# todėl norint žinoti tikimybę jog studentas atsakys į 4 arba mažiau
dbinom(x=0, size = 10, prob = 0.25)+
        dbinom(x=1, size = 10, prob = 0.25)+
        dbinom(x=2, size = 10, prob = 0.25)+
        dbinom(x=3, size = 10, prob = 0.25)+
        dbinom(x=4, size = 10, prob = 0.25)
## [1] 0.9218731
# sum(mapply(dbinom, 0:4, 10,.25))

# alternatyviai galima pasinaudoti pbinom()
pbinom(q=4, size= 10, prob = 0.25, lower.tail = TRUE)
## [1] 0.9218731
# tačiau piktąjį dėstytoją domina,
# kokia tikimybė, jog studentas "praslys":
pbinom(q=4, size= 10, prob = 0.25, lower.tail = FALSE)
## [1] 0.07812691
```

Binominis skirstinys

```
x <- seq(from=0, to=10, by=1)
y <- pbinom(x, size=10, prob=0.25)
plot(x,y, type = "b")
axis(side = 1, at = x,labels = T)
```

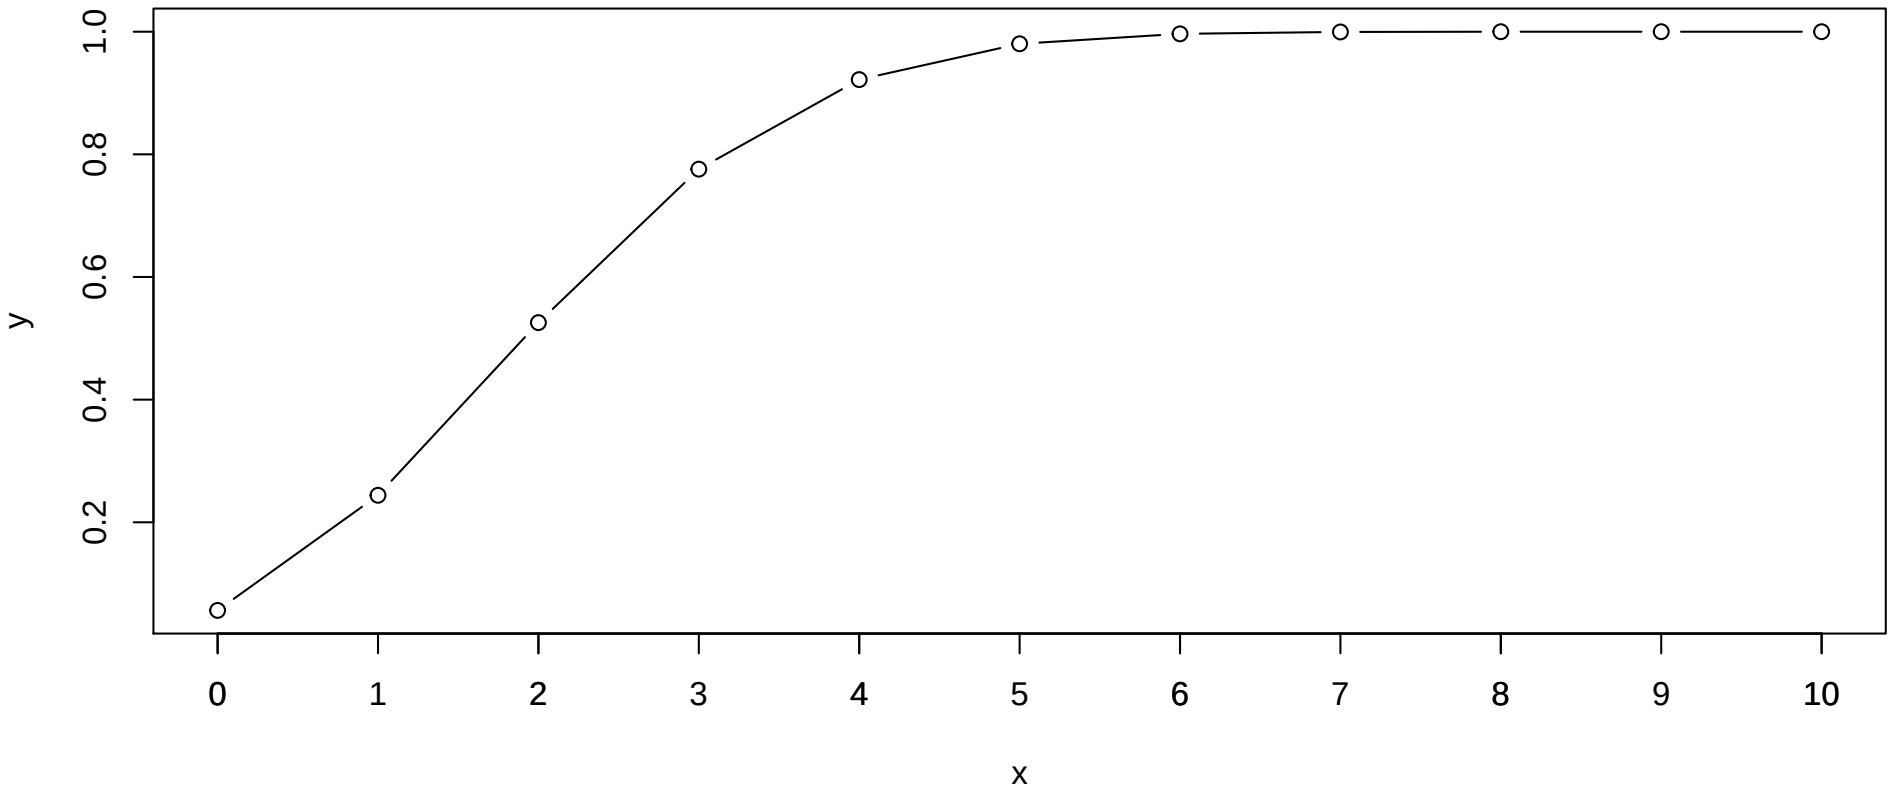

Binominis skirstinys

Tarkime dėstytojas nori nustatyti ribą, į kiek klausimų turi teisingai atsakyti studentai, kai:

- studentai turėdami 4 galimus pasirinkimus (daugiau alternatyvių atsakymų dėstytojas nenori sugalvoti, nes tingi)
- destyjas nenori, kad studentai praslystų pro testą didesne nei 1% tikimybe
- destytojas tingi galvoti daugiau nei 10 klausimų

```
qbinom(0.01, 10, 0.25, lower.tail = FALSE)
## [1] 6
pbinom(5,10,.25,lower.tail = FALSE)
## [1] 0.01972771
pbinom(6,10,.25,lower.tail = FALSE)
## [1] 0.003505707
```

Binominis skirstinys

```
x <- seq(from=0, to=10, by=1)
y <- pbinom(x, size=10, prob=0.25)
plot(x,y, type = "p")
axis(side = 1, at = x,labels = T)
```

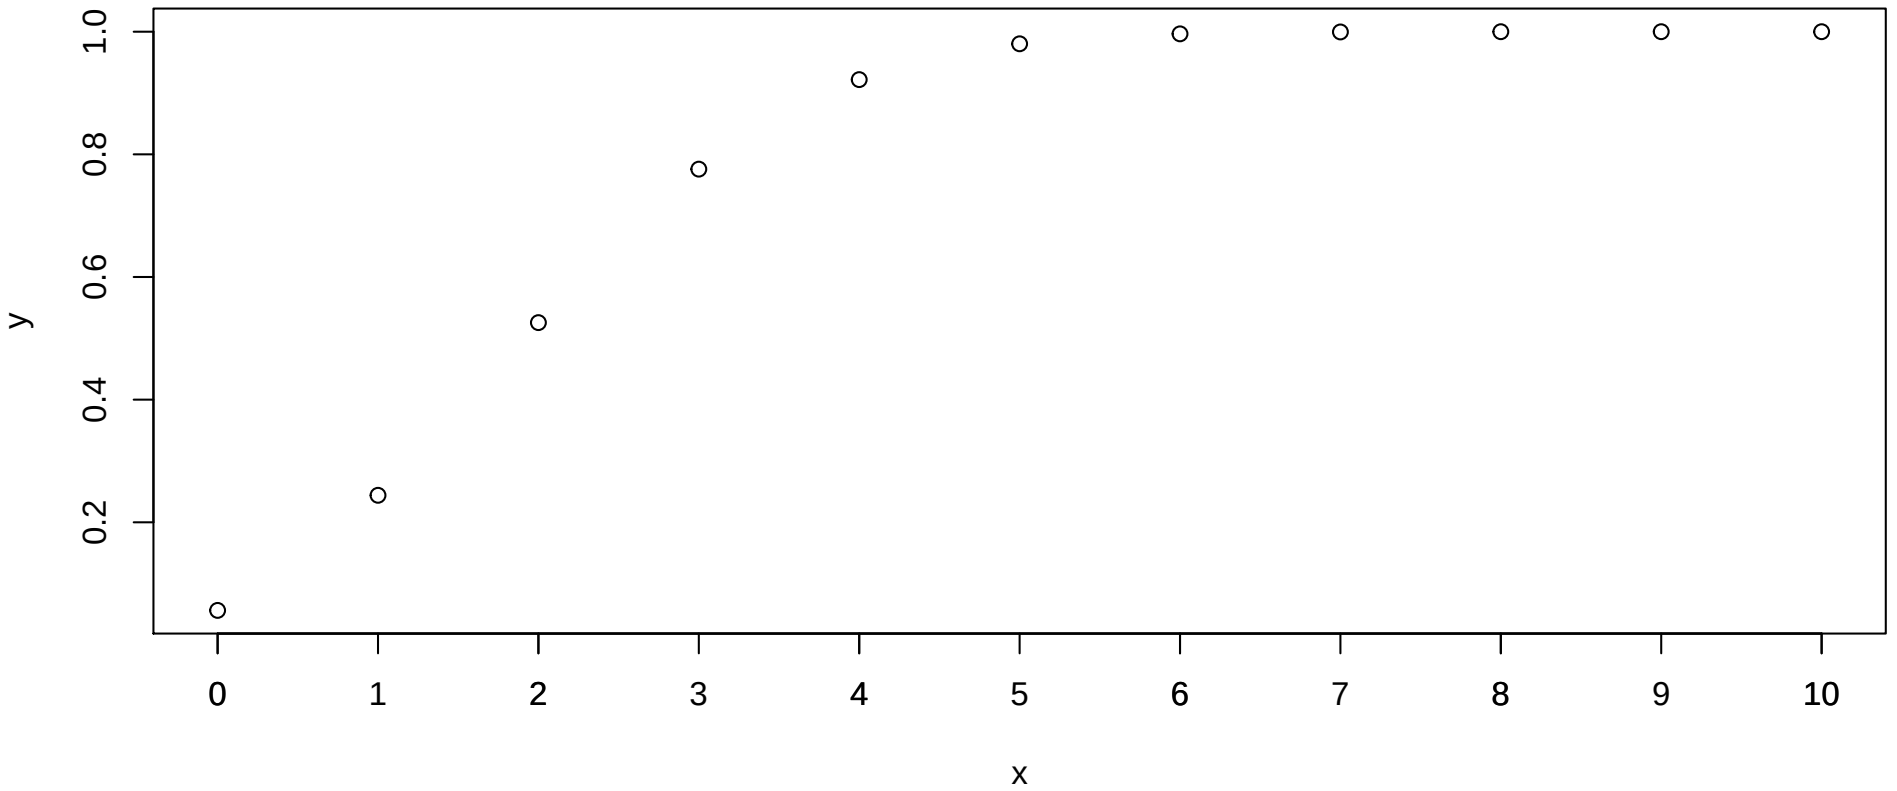

Poisson skirstinys

Poisson skirstinys

Diskretus skirstinys (tikimybių pasiskirstymo dėsnis), nusakantis įvykių tikimybes įvykti per tam tikrą laiko intervalą, jeigu įvykiai vyksta pastoviu dažniu ir yra nepriklausomi vienas nuo kito.

- Vidurkis= $\bar{k} = \lambda$
- Dispersija= $\sigma^2 = \lambda$

Jei per tam tikrą laiko intervalą įvyksta vidutiniškai λ įvykių, tuomet tikimybė, kad per tą laiką įvyks tiksliai x įvykių bus lygi:

$$f(x) = \frac{\lambda^x e^{-\lambda}}{x!} \text{ kur } x = 1, 2, 3, ..., n$$

Poisson skirstinys

Poisson distribucija, kur λ yra vidutinė įvykio tikimybė per tam tikrą laikotarpį

```
rpois(n=10, lambda = 1)
##  [1] 0 1 1 1 1 2 1 1 1 1
rpois(n=10, lambda=2)
##  [1] 3 3 2 6 3 3 0 1 4 4
hist(rpois(n=1000, lambda=2))
```

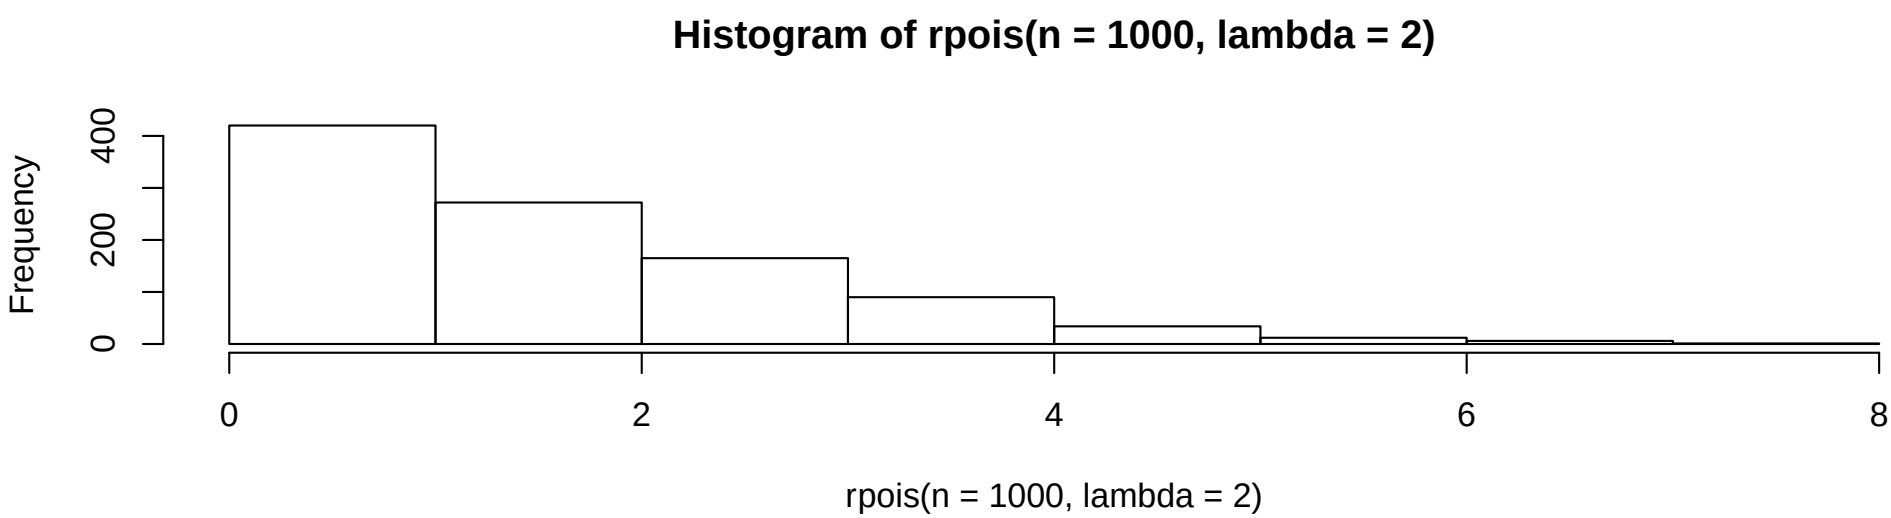

Poisson skirstinys

Skambučių centras per valandą sulaukia 50 skambučių. *Maximum capacity* yra 65 skambučiai per valandą. Tada skambučiai nukreipiami į alternatyvų skambučių centrą, kuriame dirba beždžionėlės, tad klientai visad lieka nepatenkinti. Klausimas, kokia yra tikimybė, jog per sekančią valandą skambučių centras sulauks: 5, 30, 60 (arba mažiau skambučių):

```
dpois(5, 50) ## 5 Pr(x=5), lambda=50
## [1] 5.022786e-16
dpois(30 , 50) ## 30  Pr(x=30), lambda=50
## [1] 0.0006771985
dpois(60, 50) ## 60  Pr(x=50), lambda=50
## [1] 0.02010487

ppois(5, 50) ## 5 arba mažiau skambučių Pr(x<=5), lambda=50
## [1] 5.567756e-16
ppois(30, 50) ## 30 arba mažiau skambučių Pr(x<=30), lambda=50
## [1] 0.001594027
ppois(60, 50) ## 60 arba mažiau skambučių Pr(x<=50),lambda=50
## [1] 0.9278398
```

Poisson skirstinys

Exercise:

Kokia tikimybė, jog skambučių centras sulauks daugiau skambučių nei skambučių centro maksimalus aptarnavimo limitas?

Jeigu įmonės išsikeltas tiklsas, jog nepatenkintų klientų būtų mažiau nei 0.1%, ar patartumėte vadovybei plėsti skambučių centro galimybes? Kiek papildomų darbuotojų reikia nusamdyti skambučiui centrui, jeigu 1 darbuotojas gali priimti po 5 skambučius per valandą?

Tolygusis skirstinys (Continuous uniform distribution)

Tolygusis skirstinys (Continuous uniform distribution)

Skirstinys su vienoda tikimybe visiems skaičiams tarp a ir b. Visais kitais atvejais tikimybė =0.

$$f(x) = \begin{cases} \frac{1}{b-a} \text{ when } a \leq x \leq b \\ 0, else \end{cases}$$

Tolygusis skirstinys (Continuous uniform distribution)

```
dist <- runif(n=1000, min=2, max=5)
hist(dist, breaks = seq(from=0, to=6, by=1))
```

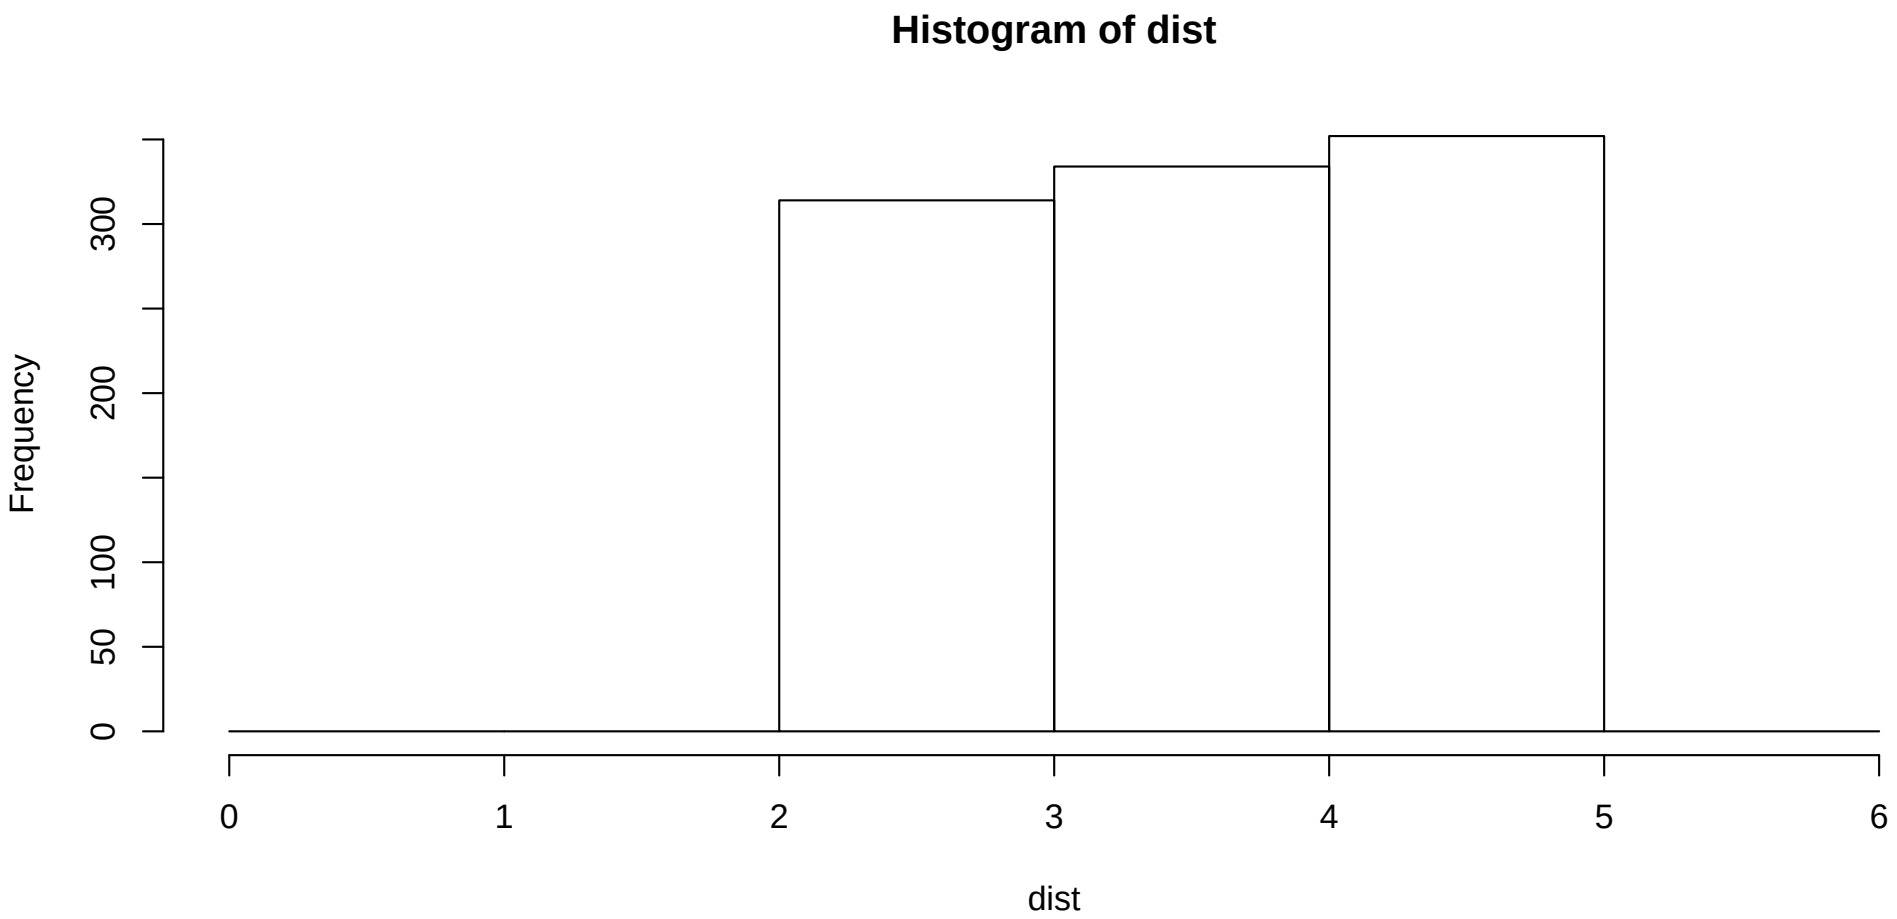

Eksponentinis skirstinys

Eksponentinis skirstinys

is the probability distribution that describes the time between events in a Poisson point process, i.e., a process in which events occur continuously and independently at a constant average rate

$$f(x, \lambda) = \begin{cases} \lambda e^{-\lambda x}, \text{ when } x \geq 0 \\ 0, x < 0 \end{cases}$$

$$f(x, \mu) = \begin{cases} \frac{1}{\mu} e^{-x/\mu}, \text{ when } x \geq 0 \\ 0, x < 0 \end{cases}$$

Eksponentinis skirstinys

```
?dexp
```

Eksponentinis skirstinys

PVZ: Tarkime kasininkas aptarnauja vieną klientą per vidutiniškai 3 minutes. Žinoma, kad aptarnavimo laikas turi eksponentinį skirstinį. Kokia tikimybe sekantis klientas bus aptarnautas per mažiau nei 2 minutes

- vidutinis aptarnavimo greitis: 1/3=0.333 klientų per minutę

```
pexp(2, rate=1/3)
## [1] 0.4865829
```

Eksponentinis skirstinys

```
x <- seq(from=0, to=10, by=1)
y <- dexp(x, rate=1/3 )
plot(x,y, type = "l")
axis(side = 1, at = x,labels = T)
```

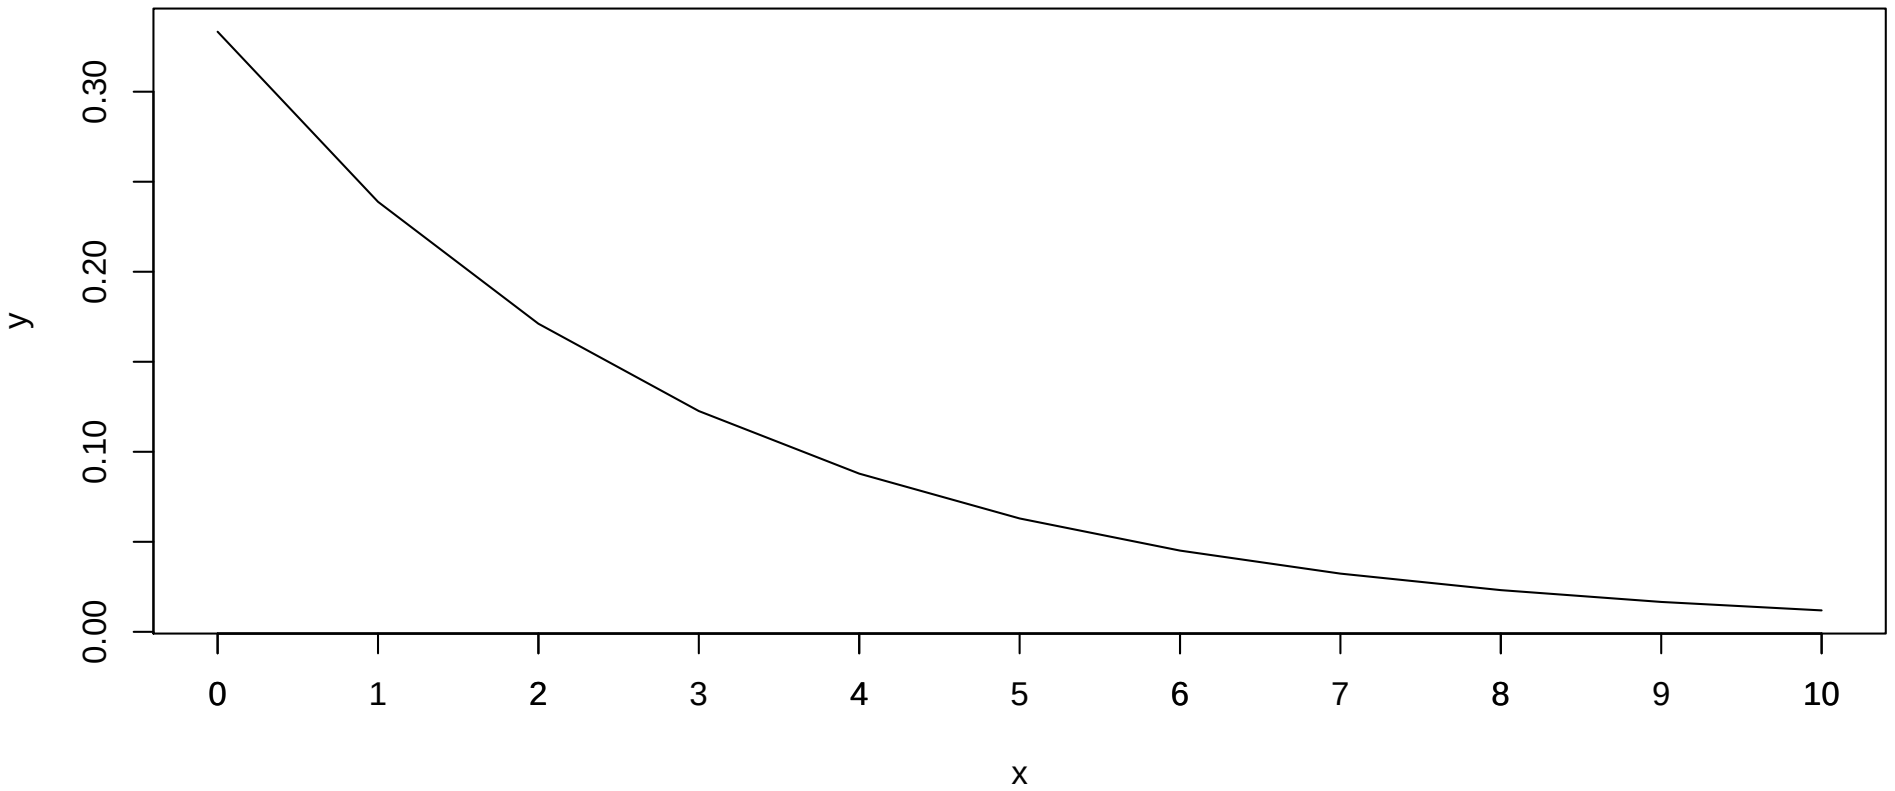

Eksponentinis skirstinys

```
x <- seq(from=0, to=10, by=1)
y <- pexp(x, rate=1/3 )
plot(x,y, type = "l")
axis(side = 1, at = x,labels = T)
```

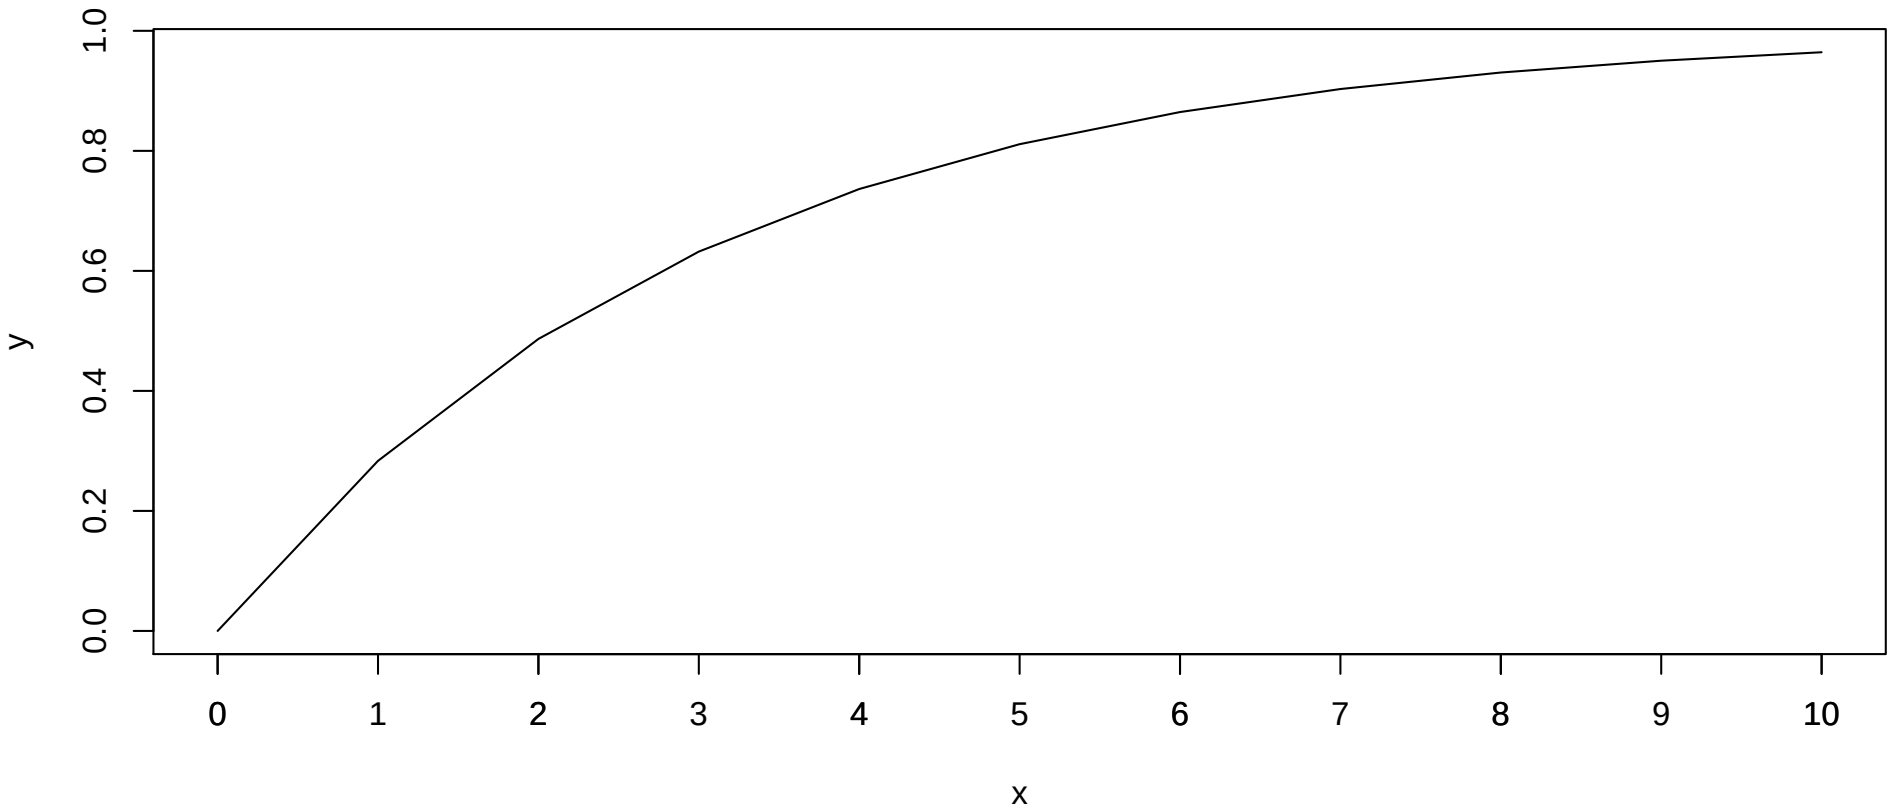

Normalusis skirstinys

Normalusis skirstinys

Sakysime, kad atsitiktinis dydis x turi normalųjį skirstinį, jei jo tankis

$$\varphi_{\mu,\sigma}(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(x-\mu)^2/(2\sigma^2)} \text{ for } -\infty < x < \infty; -\infty < \mu < \infty, \sigma^2 > 0$$

Sakysime, kad atsitiktinis dydis x turi standartinį normalųjį skirstinį, jeigu $\mu = 0, \sigma^2 = 1$

Normalusis skirstinys

```
x <- seq(from=-5, to=5, by=0.2)
y <- dnorm(x)
plot(x,y, type = "p")
axis(side = 1, at = x,labels = F)
```

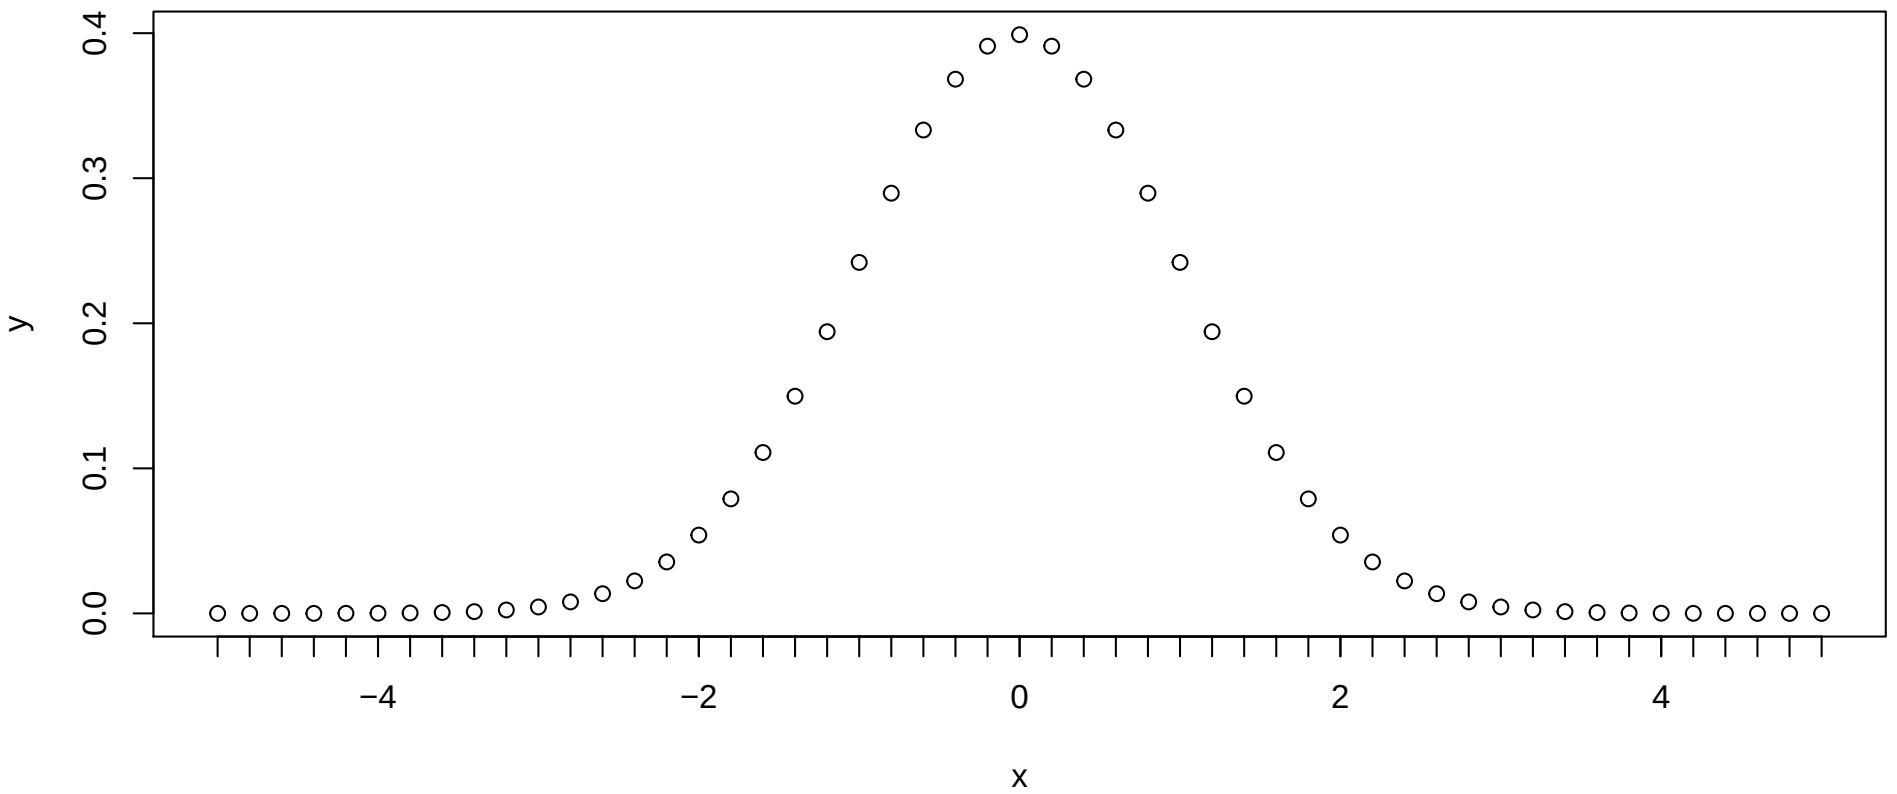

Normalusis skirstinys

```
x <- seq(from=-5, to=5, by=0.2)
y <- pnorm(x)
plot(x,y, type = "p")
axis(side = 1, at = x,labels = F)
```

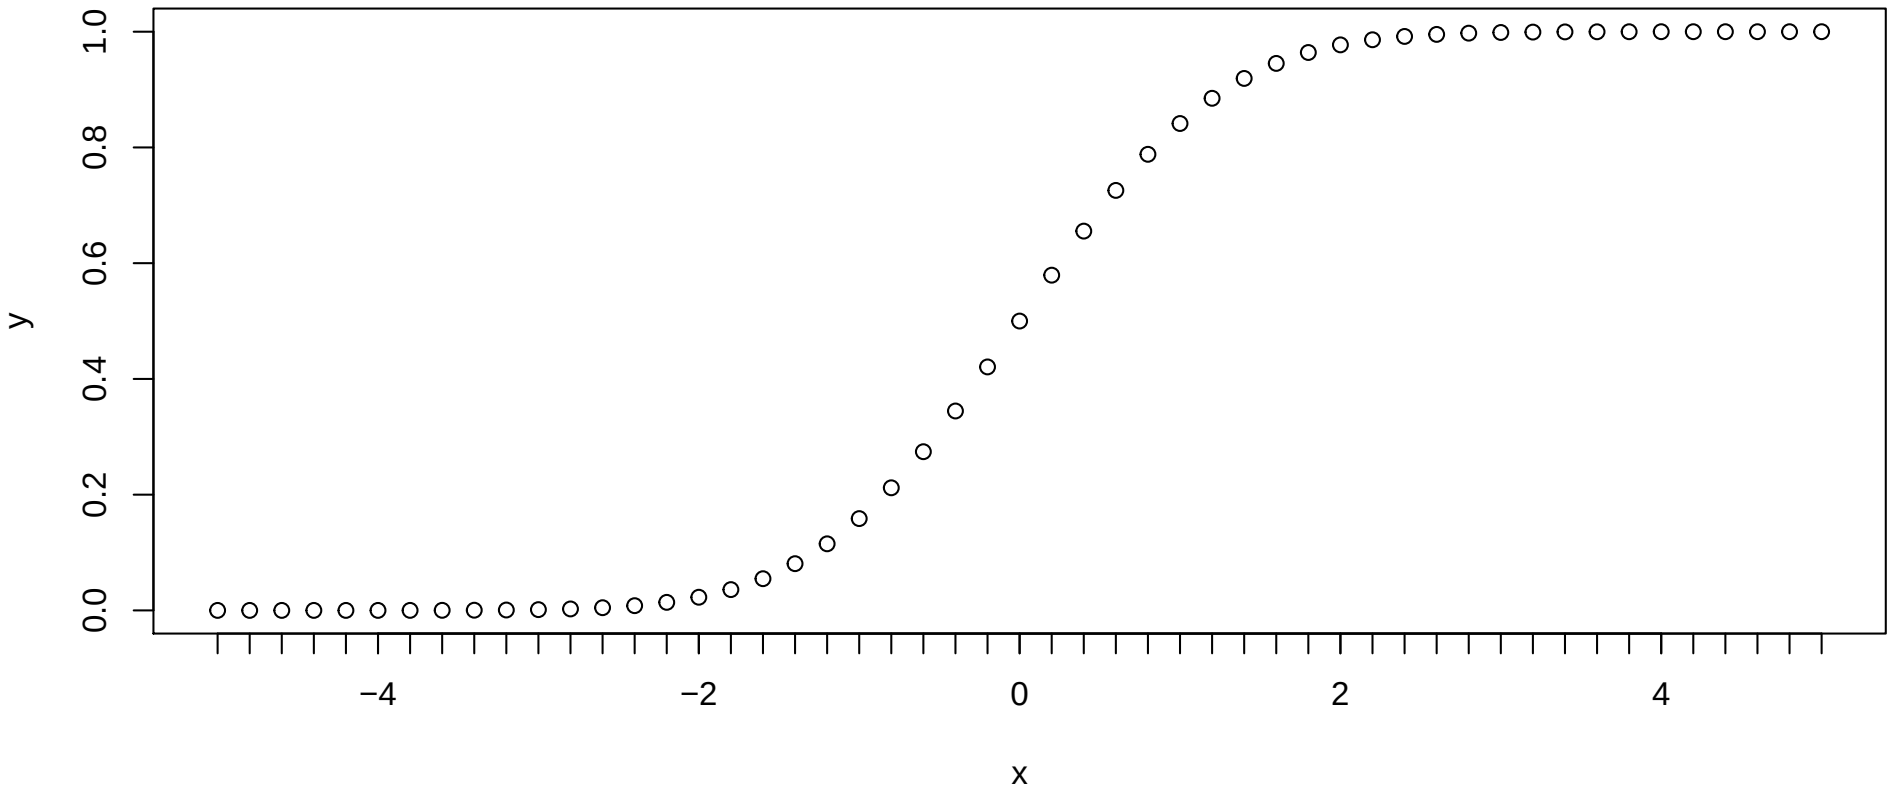

Normalusis skirstinys

- Tarkime yra žinoma, jog ūgis turi normalūjų skirstinį
- 1 kurso vidurkis: 1.70, standartinis nuokrypis: 10
- klausimai:
  - kokia tikimyybė, jog auditorijoje bus 1.5m arba mažesnis asmuo
  - kokia tikimybė, jog auditorijoje bus 1.85m arba didesnis asmuo
  - iki kokio ūgio bus 95% visų studentų

Normalusis skirstinys

Solutions:

```
## [1] 0.02275013
## [1] 0.0668072
## [1] 1.864485
```