

# Duomenų analizės įvadas

## 2.2. dalis - R programavimas

Justas Mundeikis

VU EVAF

2019-03-16

# Turinys

- 1 Loop funkcijos
- 2 lapply
- 3 sapply
- 4 mapply
- 5 tapply
- 6 split
- 7 Distribucijos
- 8 Binomial distribution
- 9 Poisson distribution
- 10 Continuous uniform distribution
- 11 Exponential distribution
- 12 Normal distribution

# Loop funkcijos

# Loop funkcijos

Rašant skriptus, `for`, `while` ir kiti loopai yra tinkami, bet jeigu norima parašyti kodą tiesiog konsolėje, tada susiduriama su daug problemų.

- `lapply`: loopina per list ir paleidžia funkciją kiekvienam elementui
- `sapply`: kaip ir `lapply` tik supaprastina rezultatus
- `apply`: taiko funkciją 'over the margins of an array'
- `tapply`: taiko funkciją vektorių dalims
- `mapply`: multivariatinė `lapply` versija

lapply

# lapply

lapply priima 3 argumentus: (1) list objektą, (2) funkciją arba funkcijos pavadinimą, (3) galimus funkcijos papildomus argumentus

Jeigu X nėra list, tada R bando paversti X list objektu.

```
args(lapply)
## function (X, FUN, ...)
## NULL
lapply
## function (X, FUN, ...)
## {
##     FUN <- match.fun(FUN)
##     if (!is.vector(X) || is.object(X))
##         X <- as.list(X)
##     .Internal(lapply(X, FUN))
## }
## <bytecode: 0x5566529da958>
## <environment: namespace:base>
```

# lapply

lapply visad grąžina list klasės objektą

```
x <- list(a=1:10, b=rnorm(10), c=seq(from=100, to=200, by=2))
lapply(x, mean)
## $a
## [1] 5.5
##
## $b
## [1] 0.2524767
##
## $c
## [1] 150
```

# lapply

```
x <- 1:3
as.list(1:3)
## [[1]]
## [1] 1
##
## [[2]]
## [1] 2
##
## [[3]]
## [1] 3
lapply(x, runif)
## [[1]]
## [1] 0.6719481
##
## [[2]]
## [1] 0.4234126 0.2658082
##
## [[3]]
## [1] 0.4173505 0.2407724 0.6552593
```



# lapply

Išnaudojant ... galime perleisti papildomus argumentus runif funkcijai:

```
x <- 1:3
as.list(1:3)
## [[1]]
## [1] 1
##
## [[2]]
## [1] 2
##
## [[3]]
## [1] 3
lapply(x, runif, min=5, max=10)
## [[1]]
## [1] 8.725853
##
## [[2]]
## [1] 8.815029 7.111812
##
## [[3]]
```

# lapply

lapply ir kitos apply funkcijos gali naudotis anoniminėmis funkcijomis, t.y. niekur kitur nedefinuotomis funkcijomis

```
x <- list(a=matrix(1:9, nrow=3, ncol = 3), b=matrix(1:4, nrow = 2, ncol=2))
lapply(x, function(elt) elt[,1, drop=FALSE]) #elt yra anoniminė funkcija
## $a
##      [,1]
## [1,]    1
## [2,]    2
## [3,]    3
##
## $b
##      [,1]
## [1,]    1
## [2,]    2
```

supply

# sapply

sapply bando supaprastinti lapply rezultatus, jeigu įmanoma

- jeigu lapply grąžintu list, kurių kiekvienas elementas yra 1 ilgumo, tada sapply grąžina vektorių
- jeigu lapply grąžintu list, kurių kiekvienas elementas yra  $>1$  ir vienodo ilgumo, tada sapply grąžina matricą
- jeigu netinka pirma du variantai, grąžina list

# sapply

```
x <- list(a=1:10, b=rnorm(10), c=seq(from=100, to=200, by=2))
lapply(x, mean)
## $a
## [1] 5.5
##
## $b
## [1] 0.4251241
##
## $c
## [1] 150
```

# sapply

```
x <- list(a=1:10, b=rnorm(10), c=seq(from=100, to=200, by=2))
sapply(x, mean)
##           a           b           c
##  5.5000000  0.1021237 150.0000000
```

# apply

`apply` naudojama taikyti funkcijas dataframe, matricų eilutėms ar stulpeliams. `apply` iš esmės supaprastina `for` loop naudojimą.

```
str(apply)  
## function (X, MARGIN, FUN, ...)
```

# apply

```
x <- matrix(1:4,2,2)
x
##      [,1] [,2]
## [1,]    1    3
## [2,]    2    4
apply(x, 1, mean)
## [1] 2 3
apply(x, 2, mean)
## [1] 1.5 3.5
apply(x, 1, sum)
## [1] 4 6
apply(x, 2, sum)
## [1] 3 7
```



# apply

Jeigu norima apskaičiuoti dataframe / matricų eilųčių ar stulpelių sumas / vidurkius, galima naudoti jau supaprastintas funkcijas, jos veikia dar greičiau, nei originalas.

```
rowSums=apply(x,1,sum) rowMeans=apply(x,1,mean)  
colSums=apply(x,2,sum) colMeans=apply(x,2,mean)
```

# apply

```
x <- matrix(rnorm(200),20,10)
apply(x, 1, quantile, probs=c(0.25 ,0.5, 0.75))
```

##		[,1]	[,2]	[,3]	[,4]	[,5]	[,6]
## 25%		-1.1004017	-0.8547683	-1.2813248	-0.64945572	-0.2201941	-1.07191246
## 50%		0.1221921	-0.1906842	0.2143838	-0.09093318	0.2011061	-1.01919673
## 75%		0.5222819	0.5919317	0.8878092	0.23082686	0.7551597	0.09217805
##		[,7]	[,8]	[,9]	[,10]	[,11]	[,12]
## 25%		-0.1331935	-0.2481558	-1.4190440	-1.1612452	-1.2993890	-1.0763143
## 50%		0.4863995	0.1885003	-0.1680950	-0.4400157	-0.9043489	-0.3308245
## 75%		0.5678069	0.8258982	0.3059019	0.5369320	-0.1634602	-0.0295602
##		[,13]	[,14]	[,15]	[,16]	[,17]	[,18]
## 25%		-0.3943433	-0.945413692	-1.5419104	-0.97948907	-1.0413642	-0.7838835
## 50%		0.2711753	0.003369702	-0.3199503	-0.54684740	-0.1477208	-0.0948046
## 75%		0.9172764	0.611524161	0.6634889	-0.07339726	0.4383544	0.5979586
##		[,19]	[,20]				
## 25%		-0.3208434	-0.9617296				
## 50%		0.1115974	-0.1689614				
## 75%		0.5849055	0.1932603				

# apply

```
x <- array(data=rnorm(40), dim = c(2,2,10))
apply(x, c(1,2), mean)
##           [,1]      [,2]
## [1,] -0.3875616  0.29571962
## [2,] -0.2949055 -0.02082904
```

mapply

# mapply

`mapply` taiko paraleliai (vienu metu) funkciją skirtingiems argumentams

```
str(mapply)
## function (FUN, ..., MoreArgs = NULL, SIMPLIFY = TRUE, USE.NAMES = TRUE)
```

- `FUN` yra funkcija, kuri bus taikoma
- `...` argumentai, kuriais naudojamosi funkcijoje
- `MoreArgs` kiti `FUN` argumentai
- `SIMPLIFY` ar rezultatas turėtų būti simplifikuotas kaip `sapply`

## mapply

```
list(rep(1,4), rep(2,3), rep(3,2), rep(4,1))  
## [[1]]  
## [1] 1 1 1 1  
##  
## [[2]]  
## [1] 2 2 2  
##  
## [[3]]  
## [1] 3 3  
##  
## [[4]]  
## [1] 4
```

# mapply

```
mapply(rep, 1:4, 4:1)
## [[1]]
## [1] 1 1 1 1
##
## [[2]]
## [1] 2 2 2
##
## [[3]]
## [1] 3 3
##
## [[4]]
## [1] 4
```

## mapply

```
noise <- function(n, mean, sd){  
  rnorm(n, mean, sd)  
}  
  
noise(4,1,2)  
## [1] 0.815746 1.575084 -1.330642 1.411042  
noise(1:4,1:4,0.01)  
## [1] 0.994897 2.003265 2.998282 3.998115
```



## mapply

```
noise <- function(n, mean, sd){  
  rnorm(n, mean, sd)  
}  
  
mapply(noise, 1:4, 1:4, 0.1)  
## [[1]]  
## [1] 1.013708  
##  
## [[2]]  
## [1] 2.078110 2.071801  
##  
## [[3]]  
## [1] 2.998873 2.937595 3.046855  
##  
## [[4]]  
## [1] 4.104642 4.047430 3.998437 4.103961  
# list( noise(1,1,0.1),noise(2,2,0.1),noise(3,3,0.1),noise(4,4,0.1)))
```

tapply

# tapply

```
str(tapply)
## function (X, INDEX, FUN = NULL, ..., default = NA, simplify = TRUE)
```

- X yra vektorius
- INDEX faktorius arba faktorių list
- FUN taikoma funkcija
- ... papildomi FUN argumentai
- simplify ar supaprastinti rezultatus

## tapply

```

x <- c(rnorm(10), runif(10), rnorm(10,1))
x
## [1] -0.7231060  1.1326129  1.0512988 -0.2689475  0.1850268  0.2023755
## [7]  0.7552277  1.1811535 -0.2585635  0.6071436  0.2637104  0.1753065
## [13]  0.5591984  0.8262232  0.9467480  0.7652819  0.4253932  0.5710458
## [19]  0.9770959  0.9933834  0.2724219  1.3371940  1.1002621 -0.9620210
## [25]  0.3119945  3.7750138  1.8188418  1.2528800 -0.4404487 -0.3399938
# Generate factors by specifying the pattern of their levels.
#gl(n, k, length = n*k, labels = seq_len(n), ordered = FALSE)
f <- gl(3,10)
f
## [1] 1 1 1 1 1 1 1 1 1 1 2 2 2 2 2 2 2 2 2 3 3 3 3 3 3 3 3 3 3
## Levels: 1 2 3
tapply(x, f, mean)
##          1          2          3
## 0.3864222 0.6503387 0.8126144

```

# tapply

```
tapply(x, f, mean, simplify = FALSE)
## $`1`
## [1] 0.3864222
##
## $`2`
## [1] 0.6503387
##
## $`3`
## [1] 0.8126144
```

## tapply

```
tapply(x, f, summary)
## $`1`
##      Min. 1st Qu.  Median      Mean 3rd Qu.      Max.
## -0.7231 -0.1477  0.4048  0.3864  0.9773  1.1812
##
## $`2`
##      Min. 1st Qu.  Median      Mean 3rd Qu.      Max.
##  0.1753  0.4588  0.6682  0.6503  0.9166  0.9934
##
## $`3`
##      Min. 1st Qu.  Median      Mean 3rd Qu.      Max.
## -0.9620 -0.1869  0.7061  0.8126  1.3161  3.7750
```

# split

`split` padalina vektorių arba kitą objektą į grupes priklausomai nuo faktorių arba faktorių list

```
str(split)  
## function (x, f, drop = FALSE, ...)
```

- `x` vektorius / list / dataframe
- `f` faktorius arba faktorių list
- `drop` indikuoja, ar tušti faktoriai turėtų būti panaikinti

split



# split

```
x <- c(rnorm(10), runif(10), rnorm(10,1))
f <- gl(3,10)
split(x, f)
## $`1`
## [1] -0.33028847  1.53207684 -0.74501340 -1.48387865 -0.29717694
## [6]  0.21877092  0.16867412  0.46984638  0.02587648  1.29212789
##
## $`2`
## [1] 0.99327997 0.18548999 0.05223415 0.47748168 0.22374088 0.74541531
## [7] 0.08026931 0.40778336 0.30331372 0.98489960
##
## $`3`
## [1] 0.74640808 -0.06320149 1.09042925 1.65383843 1.04352568
## [6] 1.36306360 -0.87970006 1.43736967 0.75167612 0.49934197
# dabar galima naudoti lapply / sapply
```

# split

```
lapply(split(x, f), mean)
## $`1`
## [1] 0.08510152
##
## $`2`
## [1] 0.4453908
##
## $`3`
## [1] 0.7642751
tapply(x, f, mean)
##           1           2           3
## 0.08510152 0.44539080 0.76427513
```

## split

```
head(airquality)
##      Ozone Solar.R Wind Temp Month Day
## 1      41      190  7.4   67     5   1
## 2      36      118  8.0   72     5   2
## 3      12      149 12.6   74     5   3
## 4      18      313 11.5   62     5   4
## 5      NA       NA 14.3   56     5   5
## 6      28       NA 14.9   66     5   6
```

# split

```
s <- split(airquality, airquality$Month)
lapply(s, function(x) colMeans(x[,1:4]))
## $`5`
##      Ozone      Solar.R      Wind      Temp
##      NA         NA 11.62258 65.54839
##
## $`6`
##      Ozone      Solar.R      Wind      Temp
##      NA 190.16667 10.26667 79.10000
##
## $`7`
##      Ozone      Solar.R      Wind      Temp
##      NA 216.483871  8.941935 83.903226
##
## $`8`
##      Ozone      Solar.R      Wind      Temp
##      NA         NA  8.793548 83.967742
##
## $`9`
##      Ozone      Solar.R      Wind      Temp
```

# split

```
s <- split(airquality, airquality$Month)
lapply(s, function(x) colMeans(x[,1:4], na.rm=TRUE))
```

```
## $`5`
```

	Ozone	Solar.R	Wind	Temp
##	23.61538	181.29630	11.62258	65.54839

```
##
```

```
## $`6`
```

	Ozone	Solar.R	Wind	Temp
##	29.44444	190.16667	10.26667	79.10000

```
##
```

```
## $`7`
```

	Ozone	Solar.R	Wind	Temp
##	59.115385	216.483871	8.941935	83.903226

```
##
```

```
## $`8`
```

	Ozone	Solar.R	Wind	Temp
##	59.961538	171.857143	8.793548	83.967742

```
##
```

```
## $`9`
```

	Ozone	Solar.R	Wind	Temp
--	-------	---------	------	------

## split

```
s <- split(airquality, airquality$Month)
sapply(s, function(x) colMeans(x[,1:4], na.rm=TRUE))
```

##	5	6	7	8	9
## Ozone	23.61538	29.44444	59.115385	59.961538	31.44828
## Solar.R	181.29630	190.16667	216.483871	171.857143	167.43333
## Wind	11.62258	10.26667	8.941935	8.793548	10.18000
## Temp	65.54839	79.10000	83.903226	83.967742	76.90000

# split

```
regionas <- as.factor(rep(c("Vilnius", "Kaunas", "Klaidpēda"), each=10 ))
lytis <- as.factor(c("M", "V"))
x <- data.frame(metai=rep(2013:2017),
               regionas=rep(c("Vilnius", "Kaunas", "Klaidpēda"), each=10 ),
               lytis=c("M", "V"),
               bvp=rep(runif(5,100,200),3),
               vartojimas=rnorm(30)
               )
s <- (split(x, list(regionas, lytis)))
```

## split

```
head(x, 15)
```

##	metai	regionas	lytis	bvp	vartojimas
## 1	2013	Vilnius	M	182.1965	0.1374447
## 2	2014	Vilnius	V	107.5730	0.3819673
## 3	2015	Vilnius	M	143.6011	-0.5554019
## 4	2016	Vilnius	V	160.6046	0.4907543
## 5	2017	Vilnius	M	192.9062	1.1916157
## 6	2013	Vilnius	V	182.1965	0.4028319
## 7	2014	Vilnius	M	107.5730	-0.1444782
## 8	2015	Vilnius	V	143.6011	1.3912334
## 9	2016	Vilnius	M	160.6046	-0.6379880
## 10	2017	Vilnius	V	192.9062	-0.2452594
## 11	2013	Kaunas	M	182.1965	0.4925920
## 12	2014	Kaunas	V	107.5730	-0.7312743
## 13	2015	Kaunas	M	143.6011	-0.7074130
## 14	2016	Kaunas	V	160.6046	-0.8076628
## 15	2017	Kaunas	M	192.9062	0.2572263



## split

```
head(s,2)
## $Kaunas.M
##      metai regionas lytis      bvp vartojimas
## 11  2013    Kaunas      M 182.1965  0.4925920
## 13  2015    Kaunas      M 143.6011 -0.7074130
## 15  2017    Kaunas      M 192.9062  0.2572263
## 17  2014    Kaunas      M 107.5730 -0.1033139
## 19  2016    Kaunas      M 160.6046 -0.2459296
##
## $Klaidpėda.M
##      metai regionas lytis      bvp vartojimas
## 21  2013 Klaidpėda      M 182.1965 -0.1987318
## 23  2015 Klaidpėda      M 143.6011 -0.8170531
## 25  2017 Klaidpėda      M 192.9062  1.6554127
## 27  2014 Klaidpėda      M 107.5730 -0.4579310
## 29  2016 Klaidpėda      M 160.6046  1.9531693
```

## split

```
sapply(s, function(x) mean(x[,4]))
##      Kaunas.M Klaipėda.M   Vilnius.M      Kaunas.V Klaipėda.V   Vilnius.V
##      157.3763    157.3763    157.3763    157.3763    157.3763    157.3763
sapply(s, function(x) colMeans(x[,4:5]))
##              Kaunas.M Klaipėda.M      Vilnius.M      Kaunas.V Klaipėda.V
## bvp          157.37628375 157.3762837 157.376283747 157.3762837 157.3762837
## vartojimas  -0.06136762   0.4269732  -0.001761549  -0.1475587  -0.5791466
##              Vilnius.V
## bvp          157.3762837
## vartojimas   0.4843055
```

# Distribucijos

# Distribucijos

Ne retai atliekant įvairius tyrimus ar skaičiuojant tikimybes statistikoje, reikės remtis tam tikrais skirstiniais. R gali generuoti įvairius skirstinius (*distributions*) ?distributions

- dnorm
- dgamma
- beta
- dpois

ir t.t.

# Distribucijos

Šioje dalyje aptarsime

- Binomial Distribution
- Poisson Distribution
- Continuous Uniform Distribution
- Exponential Distribution
- Normal Distribution

# Distribucijos

Visos distribucijos galimos su 4 funkcijomis:

```
# ?dnorm
```

```
dnorm(x, mean = 0, sd = 1, log = FALSE)
pnorm(q, mean = 0, sd = 1, lower.tail = TRUE, log.p = FALSE)
qnorm(p, mean = 0, sd = 1, lower.tail = TRUE, log.p = FALSE)
rnorm(n, mean = 0, sd = 1)
```

- d density
- r random number generation
- p cumulative distribution
- q quantile function

## set.seed(...)

Ypatingai savo tyrimuose, jeigu naudojant sugeneruotus atsitiktinius skaičius iš tam tikro skirstinio, būtina naudoti `set.seed()`, tam, jog tyrimas būtų atkartojamas.

```
set.seed(1)
rnorm(n=5, mean=5, sd=2)
## [1] 3.747092 5.367287 3.328743 8.190562 5.659016
rnorm(n=5, mean=5, sd=2)
## [1] 3.359063 5.974858 6.476649 6.151563 4.389223
set.seed(1)
rnorm(n=5, mean=5, sd=2)
## [1] 3.747092 5.367287 3.328743 8.190562 5.659016
```

## Binominis skirstinys

Dichotomine matavimų skale matuojamų požymių reikšmių skirstinys. Skirstinys yra diskretus ir apibūdinamas parametrais  $n$  ir  $p$ . Parametras  $n \geq 0$  reiškia bandymų skaičių, o  $p$  – požymio tikimybę įgyti vieną iš dviejų galimų reikšmių.

Binominio skirstinio pasiskirstymo tankio funkcija (tikimybė gauti  $x$  reikmę su  $n$  bandymų ir  $p$  tikimybės reikmše):

$$f(x) = \binom{n}{x} p^x (1-p)^{n-x} \text{ kur } x = 1, 2, 3, \dots, n$$



# Binomial distribution

# Binomial distribution

Tarkime duomenų analizės teste yra 10 klausimų, kurių kiekvienas turi 4 galimus atsakymus, iš kurių tik vienas yra teisingas. Tarkime studentas atėjo visiškai nepasiruošęs ir visiškai atsitiktinai apsirinks atsakamus. Norint išlaikyti testą, reikia teisingai ataktyti į ne mažiau kaip 5 klausimus. Kokia tikimybė, jog studentas neišlaikys testo?

- $p = 1/4 = 0.25$  ir  $(1-p) = 1 - 0.25 = 0.75$
- $n = 10$
- $x = 4$


# Binomial distribution

- $p = 1/4 = 0.25$  ir  $(1-p) = 1 - 0.25 = 0.75$
- $n = 10$
- $x = 4$

```
# tikimybė jog studentas atsakys lygiai 4 teisingai  
dbinom(x=4, size = 10, prob = 0.25)  
## [1] 0.145998
```

# Binomial distribution

```
x <- seq(from=0, to=10, by=1)
y <- dbinom(x, size=10, prob=0.25)
plot(x,y, type = "p")
axis(side = 1, at = x, labels = T)
```



# Binomial distribution


tačiau norint žinoti visas vertes iki 4

```
# todėl norint žinoti tikimybę jog studentas atsakys į 4 arba mažiau
dbinom(x=0, size = 10, prob = 0.25)+
  dbinom(x=1, size = 10, prob = 0.25)+
  dbinom(x=2, size = 10, prob = 0.25)+
  dbinom(x=3, size = 10, prob = 0.25)+
  dbinom(x=4, size = 10, prob = 0.25)
## [1] 0.9218731
```

```
# alternatyviai galima pasinaudoti pbinom()
pbinom(q=4, size= 10, prob = 0.25, lower.tail = TRUE)
## [1] 0.9218731
# tačiau piktąjį dėstytoją domina,
# kokia tikimybė, jog studentas "praslys":
pbinom(q=4, size= 10, prob = 0.25, lower.tail = FALSE)
## [1] 0.07812691
```

# Binomial distribution

```
x <- seq(from=0, to=10, by=1)
y <- pbinom(x, size=10, prob=0.25)
plot(x,y, type = "p")
axis(side = 1, at = x, labels = T)
```



# Binomial distribution


Tarkime dėstytojas nori nustatyti ribą, i kiek klausimų turi teisingai atsakyti studentai, kai:

- studentai turėdami 4 galimus pasirinkimus (daugiau alternatyvių atsakymų dėstytojas nenori sugalvoti, nes tingi)
- dėstytojas nenori, kad studentai praslystų pro testą didesne nei 10% tikimybe
- dėstytojas tingi galvoti daugiau nei 10 klausimų

```
qbinom(0.1, 10, 0.25, lower.tail = FALSE)
## [1] 4
```

# Binomial distribution

```
x <- seq(from=0, to=10, by=1)
y <- pbinom(x, size=10, prob=0.25)
plot(x,y, type = "p")
axis(side = 1, at = x, labels = T)
```





# Poisson distribution

# Poisson distribution

Dichotomine matavimų skale matuojamų požymių reikšmių skirstinys. Skirstinys yra diskretus ir apibūdinamas parametrais  $n$  ir  $p$ . Parametras  $n \geq 0$  reiškia bandymų skaičių, o  $p$  – požymio tikimybę įgyti vieną iš dviejų galimų reikšmių.

Binominio skirstinio pasiskirstymo tankio funkcija (tikimybė gauti  $x$  reikmę su  $n$  bandymų ir  $p$  tikimybės reikmše):

$$f(x) = \frac{\lambda^x e^{-\lambda}}{x!} \text{ kur } x = 1, 2, 3, \dots, n$$

# Poisson distribution

## Poisson distribucija

```
# ?dpois
```


```
dpois(x, lambda, log = FALSE)
ppois(q, lambda, lower.tail = TRUE, log.p = FALSE)
qpois(p, lambda, lower.tail = TRUE, log.p = FALSE)
rpois(n, lambda)
```

# Poisson distribution

Poisson distribucija, kur  $\lambda$  yra vidutinė įvykio tikimybė per tam tikrą laikotarpį

```
rpois(n=10, lambda = 1)
## [1] 0 0 1 1 2 1 1 4 1 2
rpois(n=10, lambda=2)
## [1] 4 1 2 0 1 1 0 1 4 1
hist(rpois(n=1000, lambda=2))
```

Histogram of rpois(n = 1000, lambda = 2)



# Poisson distribution

Poisson distribucija, kur  $\lambda$  yra vidutinė įvykio tikimybė per tam tikrą laikotarpį.

Skambučių centras per valandą sulaukia 50 skambučių. *Maximum capacity* yra 65 skambučiai per valandą. Tada skambučiai nukreipiami į alternatyvų skambučių centrą, kuriame dirba beždžionėlės, tad klientai visad lieka nepatenkinti.

Klausimas, kokia yra tikimybė, jog per sekančią valandą skambučių centras sulauks: 5, 30, 60 (arba mažiau skambučių):

```
dpois(5, 50) ## 5 Pr(x=5), lambda=50
## [1] 5.022786e-16
dpois(30, 50) ## 30 Pr(x=30), lambda=50
## [1] 0.0006771985
dpois(60, 50) ## 60 Pr(x=50), lambda=50
## [1] 0.02010487
```

```
ppois(5, 50) ## 5 arba mažiau skambučių Pr(x<=5), lambda=50
## [1] 5.567756e-16
```

# Poisson distribution

Kokia tikimybė, jog skambučių centras sulauks daugiau nei skabučių centro maksimalus limitas? Jeigu įmonės išsikeltas tikslas, jog nepatenkintų klientų būtų mažiau nei 1%, ar patartumėte vadovybei plėsti skambučių centro galimybes? Kiek papildomų darbuotojų reikiai nusamdyti skambučiui centrui, jeigu 1 darbuotojas gali priimti 5 skambučius?

```
ppois(q=65, lambda = 50, lower.tail = TRUE)
## [1] 0.9827354
ppois(q=65, lambda = 50, lower.tail = FALSE)
## [1] 0.01726457

# Kiek papildomų skambučių reikėtų papildomai galėti priimti?
qpois(p=0.01, lambda = 50, lower.tail = FALSE)
## [1] 67
ceiling(
  (qpois(p=0.01, lambda = 50, lower.tail = FALSE) - 50) / 5
)
## [1] 4
```

## Continuous uniform distribution

# Exponential distribution



# Normal distribution