Duomenų analizės įvadas

1. Dalis

Justas Mundeikis

2019 m. vasario 21 d.

1. Dalies turinys

- Įvadas į duomenų analizę
 - Duomenų analizės menas
 - Duomenų analizės epiciklai
 - Duomenų analizės klausimai
 - Duomenys, matavimo skalės
- Command line interface
 - Intro
 - Direktorijos
 - CLI komandos
- Git ir GitHub
 - Intro
 - Darbas su Git
 - Git branch
 - Markdown sintaksė
- Google Scholar

1 pav.: To paties matymas kitaip











2 pav.: Taip atrodo "duomenys"



3 pav.: Taip atrodo, ką galima padaryti su duomenimis



Trumpa diskusija: ar Lietuvos Tax/GDP (29.6 %) yra gerai, ar blogai? Gal verta perimti Airijos modelį?

Justas Mundeikis Duomenu analizės įvadas 2019 m. vasario 21 d.

5 / 104

- "Science is knowledge which we understand so well that we can teach
 it to a computer; and if we don't fully understand something, it is an
 art to deal with it."
 Donald Knuth (1974) (Knuth: Computer Programming as an Art)
- Neegzistuoja jokio formalaus aprašymo, kaip reikia atlikti "duomenų analizę"
- Nors yra žinomi tam tikri įrankiai, statistiniai, ekonometriniai metodai, kuriais galima naudotis...
- Kiekvieno "tyrėjo" (ekonomisto, duomenų analitiko, studento...)
 asmeninių pasirinkimų aibė nulemia atliekamos analizės kokybę bei naudą

Mokslinio tyrimo žingsniai

- Labai daug skaityti (Savaitiniai skaitiniai: 3-6 straipsnius per savaitę, žinių (testo) dalis!)
- Išvystyti klausimą / hipotezę
- Nuspręsti kokia metodika bus taikoma
- Parengti duomenų surinkimo procesą (tyrimo protokolas)
- Surinkti duomenis
- Atlikti tiriamąją statistiką
- Atlikti aprašomąją statistiką
- Modeliuoti, atlikti prognozes
- Interpretuoti rezultatus
- Aprašyti tyrimo eigą bei rezultatus



Duomenų analizės žingsnių epiciklai


1 lentelė: The Art of Data Science (Roger D. Peng & Elizabeth Matsui)

Epycicles of analysis	Set expectations	Collect information	Revise expectations
Question	Question is of interest to audience	Literature search / Experts	Sharpen question
EDA	Data are appropriate for question	Make exploratory plots of data	Refine question or collect more data
Formal modeling	Primary model answers question	Fit secondary models, sensitivity analysis	Revise formal model to include more predictors
Interpretation	Interpretation of analyses provides a specific & meaningful answer to the question	Interpret totality of analyses with focus on effect sizes & uncertainty	Revise EDA and / or models to provide specific & interpretable answer
Communication	Process & results of analysis are understood, complete & meaningful to audiance	Seek feedback	Revise analyses or approach to presentation

ロト 4回ト 4 差ト 4 差ト き めので

Duomenų analizės žingsnių epiciklai

4 pav.: The Art of Data Science (Roger D. Peng & Elizabeth Matsui)



Remiantis R.Peng ir J.Leek (Science 2015) egzistuoja 6 klausimų tipai:

- Aprašomieji
- Tiriamieji
- Inferenciniai
- Progozuojamieji
- Pražastinių ryšių
- Mechanistiniai


Aprašomieji klausimai:

- Kuriais siekiama gauti duomenų aprašymą, arba charakteristikų santraukas
- Nedaromos jokios išvados ar prognozės, nes patys rezultatai yra išvados per se
- Pvz., Moterų ir vyrų dalis tyrimo imtyje, vidutinis tiriamųjų amžius, vidutinė metinė infliacija, medianinės pajamos ir t.t.
- LSD šalies rodikliai
- LSD statistika vizualiai

Tiriamieji klausimai

- Klausimai, kuriais siekiama nustatyti sąsajas bei trendus
- Padeda rasti kelią kuriuo galima judėti tyrime pirmyn, pvz., generuoti hipotezes
- Dažniausiai tokių klausimų atsakymui braižomi grafikai, padedantys surpasti duomenis
- Tačiau "Correlation does not imply causation" (žr sekanti skaidrė!!!)

5 pav.: Šokolado vartojimas ir Nobelio prizai (Franz H. Messerli, M.D., 2012)



Inferenciniai klausimai:

- Klausimai, kuriais siekiama atsakyti klausimus apie bendrą populiaciją, tiriant tik imtį
- Pvz., Ekonomikos kurso 1 gr. baigiamasis pažymys 8. Ar visas 1 kursas gavo 8?
- Taikant inferencinę analizę siekiama nustatyti dominantį kiekį bei su prognoze susijusią paklaidą

Prognozuojamieji klausimai

- Klausimai, kuriais siekiama "atspėti" ateitį
- Naudojant turimą informaciją apie tam tikrus objektus prognozuoti reikšmes kitiems objektams
- Svarbu: Jeigu X prognozuoja Y nereiškia, kad X iššaukia Y
- Prognozavimo taiklumas priklauso nuo teisingo matuojamų kintamųjų pasirinkimo
- Kuo daugiau duomenų ir kuo paprastesnis modelis!
- https://fivethirtyeight.com/
- AMAZON IBM E570

Priežastinių ryšių klausimai:

- Klausimai, norint sužinoti, ar pakeitus vieną faktorių, kinta kitas faktorius
- How does a lack of sleep impact memory, problem solvingand critical thinking skills amongstcollege students?
- Reikalingos randomizuotos studijos
- Ekspertimentų galimybė ekonomikos šakoje ribota
- Yra būdų kaip tai apeiti (ekonometrika magistre / PhD)
- Dažniausiai gaunami vidutiniai efektai
- Siekiama atsakyti "ar" bet ne "kaip"



Mechanistiniai klausimai

- Klausimai, kuriais siekiama nustatyti "kaip"
- Kaip ir kokie būtent pokyčiai vieno kintamojo keičia daro įtaką kitiems kintamiesiems (fizikos/inžinerijos sritis)

 Svarbu suprasti, jog pvz., iškėlus prognozuojamąjį klausimą, tyrimo eigoje bus atsakyti ir į aprašomuosius, tiriamuosius, inferencinius klausimus

Koks yra geras klausimas?

Geras klausimas pasižymi šiomis savybėmis:

- Klausimas turi būti įdomus tikslinei auditorijai
- Klausimas dar neturi būti atsakytas
- Stausimas turi būti logiškas / prasmingas (pagrįstas teorija)
- Klausimas turi būti atsakomas (netinka: "Kokia yra gyvenimo prasmė?/ Ar egzistuoja dievas?"), kitaip tariant, turi egzistuoti duomenys ir metodikos, kurių pagalba būtų galima atsakyti į klausimą
- 6 Klausimas turi būti labai konkretus
 - Blogas klausimas: ar sveika mityba skatina ilgesnį gyvenimą
 - Geras klausimas: ar 250gr daržovių kasdien suaugusiam asmeniui padidina tikėtiną gyvenimo trukmę 10 metų?
 - Blogas klausimas: kas ekonomikos nuosmukio laikotarpiu nukenčia labiausiai
 - Geras klausimas: Kurioms iš soc grupių: bedarbiai, pensininkai, daugiavaikės šeimos per ekonominę 2008-2009 krizę labiausiai padidėjo rizika patirti santykinį skurdą

Duomenys, matavimo skalės

- Duomenys yra faktai arba skaičiai, kurie yra renkami, analizuojami bei apibendrinami pristatymo ar interpretavimo tikslais
- Duomenys surinkti tam tikro tyrimo metu vadinami duomenų set'u arba duomenų masyvu
- Elementai subjektai, apie kurios renkami duomenys
- Kintamasis elemento charakteristika
- Tyrimo metu surinkti matavimai apie visus dominančius elementus ir jų kintamuosius ir yra duomenys / duomenų set'as
- Duomenų set'as vieno elemento vadinamas obzervacija

Duomenys, matavimo skalės

Kintamųjų tipas apibrėžia informacijos kiekį slypinti duomenyse, bet kartu ir apriboja galimus taikyti statistinius metodus jų analizei.

- Kategoriniai kintamieji:
 - Nominalūs kintamieji: Lytis, Spalva Galima tik suskaičiuoti vienetus
 - Ranginiai kintamieji: Dydžiai S,M,L; Kredito reitingai F AAA Juos galima prasmingai suranguoti!
- Kiekybiniai kintamieji:
 - Intervaliniai kintamieji: pažymiai (neturi 0)
 +,-, yra prasmingi, bet daugyba, dalyba nėra prasmingi
 - Santykiniai kintamieji: svoris, ūgis, atstumas (turi 0)
 +,-, daugyba, dalyba yra prasmingi

Duomenys, matavimo skalės

- 'Tarpsekciniai' duomenys (angl.: cross-sectional data): vienu ar panašiu metu užfiksuoti skirtingų elementų matavimai: pvz Europos šalių 2018m. BVP €
- Laiko eilučių duomenys (angl.: Time series data): Matavimai surinkti per du ar daugiau laikotarpių vienam elementui
- 'Tarpsekcinės' laiko eilutės (n elementų, t laikotarpiį, taigi $n \times t$ matavimų)

Big Data

- Lietuvoje dauguma įmonių nelabai supranta ką reiškia "big-data"
- Big-data be Al perteklinis duomenų kaupimas
- Problema su AI niekas nesupranta AI
- Tačiau su laiku Al keis ir ekonomikos mokslą:
- Video: AEA AFA Joint Luncheon The Impact of Machine Learning on Econometrics and Economics
- John Tukey: "The data may not contain the answer. The combination of some data and an aching desire for an answer does not ensure that a reasonable answer can be extracted from a given body of data"

Apibendrinant:

- Svarbiausias duomenų analizės / tyrimo aspektas klausimas!
- Antras pagal svarbumą duomenys
- Dažnai duomenys apribos arba išlaisvins Jus, bet tik duomenys be klausimo, neišgelbės :D



Command Line interface (CLI)

Kiekviena operacinė sistema turi CLI:

- Windows: Git Bash (), CMD
- Mac/ Linux: Terminal'as

Su CLI galima:

- Naviguoti tarp aplankų (folder'ių)
- Kurti, keisti, naikinti: failus, aplankus, programas
- Startuoti programas




Intarpas GIT Bash instaliavimas

- Nors darbiniai kompiuteriai turi instaliuotą Git Bash, tiems kas neturi:
- https://git-scm.com/
- Windows 32/64, Linux žr. komandą
- Perimti teikiamus standartinius siūlymus, nebent antrame Setup lange pasirinkti, jog Git Bash rodytų ir "Addditional icons: On the desktop"
- Startuojam Git Bash
- Nuspaudus dešinį pelės mygtuką atsidaro meniu, einame ant Options..
 - Looks: pasirenkame Curser Block (bent jau pradžiai, vėliau pasikeikite į line)
 - Keys: Ctrl+Shift+letter shortcuts pastarasis apsirinkimas leidžia daryti naudoti Crtl+C, Crtl+V tačiau reikia kartu nuspausti ir Shift!



Direktorijos

- Directory yra tiesiog kitas pavadinimas žodžiui aplankas
- Direktorijos kompiuteryje organizuotos kaip medžio šakos
- CLI padeda naviguoti tarp šių direktorijų
- "/" yra root directory Linux,
- Windows root directory yra C:
- Root directory talpina visas kitas direktorijas



Direktorijos

 Startavus matosi daug maž toks tekstas (priklausomai nuo kompiuterio jis gali skirtis!)

```
1 USER@PC MINGW64 ~ 2 $
```

- \$ ženklas (angl.: promt) reiškia: "gali rašyti komandą"
- Tipinis įrašas susideda iš: "command flag argument"
- Komandos pvz: komanda liepianti atspausdinti kurioje direktorijoje esama: pwd

```
1 USER@PC MINGW64 ~ 2 $ pwd 3 /c/Users/USER
```

Direktorijos

Universiteto kompiuteriuose pwd atsako: /c/Users/studentas

6 pav.: Kur mes esame direktorijų medyje

CLI komandos

- Komanda gali būti iššaukiama su tam tikra programa
- git init šitos komandos dabar nenaudot!
- python get-pip.py šitos komandos dabar nenaudot!
- flag: tam tikri nustatymai, galimi priklausomai nuo komandos ir visada su "-"
- argument kiti nustatymai, pakeitimai ar panašūs dalykai
- git commit —m "this is the initial commit" šitos komandos dabar nenaudot!
- jeigu flag yra žodis , tada naudojami du brūkšniai --
- git reset ——hard HASH šitos komandos dabar nenaudot!

CLI komandos

7 pav.: komanda

```
Sering the sering command in the sering command is sering to the sering command in the sering command is sering to the sering command in the sering command is sering to the sering command in the sering command is sering to the sering command in the sering command in the sering command is sering to the sering command in the
```

CLI komandos - echo

Pirmosios komandos

```
1 USER@PC MINGW64 ~
2 $ echo "hello world"
3 hello world
4 $ echo 'hello world'
5 hello world
6 $ echo hello world
7 hello world
8 $ echo "hello world
9 >
```

- arba šiuo atveju padėti ", tada Enter arba
- CRTL+C
- ESC
- q

Klaviatūros trumpiniai ir CLI komandos

```
1 USER@PC MINGW64 ~ 2 $ echo "hello world, what a beautiful day it is"
```

- Ctrl+A peršoka į eilutės pradžią (HOME)
- Crtl+E peršoka į eilutės pabaigą (END)
- Ctrl+U ištrina viską į kairę nuo cursor
- clear arba Ctrl+L išvalo langą
- arba Ctrl+D išjungia CLI

CLI komandos - cd

- cd reiškia change directory
- cd be argumentų sugrąžins į home directory
- cd.. pakels viena direktorija aukščiau
- su komanda pwd pasitikriname kur esame ir periname į Desktop
 cd Desktop
 Su komanda pwd įsitikiname, kad esame ant Desktop

```
USER@PC MINGW64 ~

pwd
/c/Users/USER

USER@PC MINGW64 ~

cd Desktop

USER@PC MINGW64 ~/Desktop

USER@PC MINGW64 ~/Desktop

pwd
/c/Users/USER/Desktop
```

CLI komandos >

echo delfi antraštę

```
USER@PC MINGW64 ~/Desktop
$ echo "Seimas proposes a reduction of MPs"
Seimas proposes a reduction of MPs
```

 Po argumento naudojam redirektoriaus simbolį > ir parašome į kur pirmą komandą nusiųsti, šiuo atveju sukuriam tekstinį failą pavadinimu delfi.txt

```
1 USER@PC MINGW64 ~/Desktop
2 $ echo "Seimas proposes a reduction of MPs" > delfi.txt
```

Ant Desktop atsiranda delfi.txt failas (atsidarom failą su Sublime)

• Jeigu padarysim taip, perrašysime delfi.txt failą

```
USER@PC MINGW64 ~/Desktop
$ echo "There are more news" > delfi2.txt
```

(atsidarom failą su Sublime)

CLI komandos » ir cat

• Jeigu norime ne perrašyti failą, o prisegti vieną eilutę, naudojame >>

```
1 USER@PC MINGW64 ~/Desktop
2 $ echo "Seimas proposes a reduction of MPs" > delfi.txt
3 $ echo "A topic heatedly discussed in public" >> delfi.txt
```

• cat (conCATonate) parodo failo turinį arba apjungia kelis failus

```
USER@PC MINGW64 ~/Desktop

choose the control of th
```

CLI komandos - Listing

- 1s nurodo visus failus ir folderius esančius direktorijoje
- Is −a nurodo visus matomus ir paslėptus failus ir folderius
- ls −al nurodo visų matomų ir paslėptų failų ir folderių detales
- 1s -rtlh tas pats kaip 1s -r -t -1 -h
- ls *.txt
- ls --help



CLI komandos - nematomi failai

- Kai kurie failai yra "nematomi", tai gali būti sisteminiai failai, arba nustatymo failai.
- Pasigaminam paslėptą failą .gitignore ir palyginame rezultatus

```
USER@PC MINGW64 ~/Desktop

secho "secrets" > .gitignore

USER@PC MINGW64 ~/Desktop

ls ...

USER@PC MINGW64 ~/Desktop

sls ...

USER@PC MINGW64 ~/Desktop

sls -a
...

...
```

CLI komandos - mkdir

- su rm ištriname ant Desktop sukurtus failus
- Pasitikriname ar nepalikome nieko ant Desktop su 1s -a

```
USER@PC MINGW64 ~/Desktop

triangle tri
```

CLI komandos - mkdir


- mkdir make directory sukuria direktoriją / folderį pvz: "S175"
- rmdir remove directory ištrina, bet tik, jeigu folderis yra tuščias
- mkdir -p s175/test sukuria direktoriją s175 (parent) ir jos viduje direktoriją test.
- Su komanda cd pereiname į sukurtą subfolderį test ir su komanda
 pwd įsitikiname ar tikrai esame ten :D

```
1 USER@PC MINGW64 ~/Desktop
2 $ mkdir -p S175/test
3
4 USER@PC MINGW64 ~/Desktop
5 $ cd S175/test
6
7 USER@PC MINGW64 ~/Desktop/S175/test
8 $ pwd
9 /c/Users/USER/Desktop/S175/test
```

CLI komandos - touch

- touch sukuria failą
- touch info.txt
- Sukuriam dvi direktorijas folder1 ir folder2
- mkdir folder1
- mkdir folder 2

8 pav.: Windows Explorer



CLI komandos - cp

cp kopijuoja failą

```
USER@PC MINGW64 ~/Desktop/S175/test

cp info.txt info2.txt

USER@PC MINGW64 ~/Desktop/S175/test

cp info.txt folder1

USER@PC MINGW64 ~/Desktop/S175/test

cp -r folder1 folder2

USER@PC MINGW64 ~/Desktop/S175/test

cp -r folder1 folder2

USER@PC MINGW64 ~/Desktop/S175/test

cp -r folder1 /c/Users/USER/Desktop/S175
```

- cp -r folder folder arba cp -r folder directory -r reiškia, jog kartu kopijuojamas ir folderio turinys
- Dabar folderyje S175 turime: folder1 ir test



CLI komandos - rm

- rm remove trina (ne į šiukšliadėžę!!!)
- rm -r su direktorijos pavadinimu viskam kas direktorijoje

```
USER@PC MINGW64 ~/Desktop/S175/test

transfer minfo2.txt

USER@PC MINGW64 ~/Desktop/S175/test

rm -r folder2

USER@PC MINGW64 ~/Desktop/S175/test

rm -r folder2

USER@PC MINGW64 ~/Desktop/S175/test

rm -r /c/Users/USER/Desktop/S175/folder1
```

CLI komandos - mw

• mw perkelia failą (Cut+Paste), arba pervadine failą

```
USER@PC MINGW64 ~/Desktop/S175/test

mv info.txt folder1

USER@PC MINGW64 ~/Desktop/S175/test

mkdir folderx

USER@PC MINGW64 ~/Desktop/S175/test

mv folderx folder2
```

- Geriausia naudoti Sublime
- Windows turi standartinį Notepad (tragedija!)

```
USER@PC MINGW64 ~/Desktop/S175/test
$ echo "This is the new text" > info.txt

USER@PC MINGW64 ~/Desktop/S175/test
$ notepad info.txt
```

 Kol neuždarytas Notepad , GitBash "laukimo" būsenoje! tad norint dirbti toliau, pirma reikia uždaryti editorių


• GitBash turi Nano, bet reikia labai įprasti!

9 pav.: Nano editorius

```
MINGW64:/c/Users/USER/Desktop/S175/test
                                                                           GNU nano 3.2
                                       info.txt
This is the new text
NG Get Help NO Write Out NW Where Is NK Cut Text NJ Justify
            AR Read File A\ Replace AU Uncut TextAT To Spell
```

- GitBash turi Nano, bet reikia labai įprasti!
- Atidarome su Nano
- Įrašome papildomą eilutę
- Uždarome su Crtl+X, Nano klausia: "Save modified buffer? .."
- Spaudžiama Y klavišą

10 pav.: Nano editorius



- Nano klausia, ar pavadinimas lieka tas pats?
- Spaudžiam Enter klavišą

11 pav.: Nano editorius

```
MINGW64:/c/Users/USER/Desktop/S175/test
                                                                                - - X
 GNU nano 3.2
                                          info.txt
                                                                              Modified
This is the new text
You can add one more line
File Name to Write: info.txt
NG Get Help
                                                                 M-B Backup File
                     M-M Mac Format
```



Wrap-up

- Iki dabar išmokome pagrindinių komandų, kuriomis galime naviguoti sistemoje
- Taip pat išmokome svarbiausias komandas, kurios ledižia dirbti su failais ir folderiais
- Tam kad būtų švarus S175/test, belieka tik ištrinti test esančius failus:

```
1 USER@PC MINGW64 ~/Desktop/S175/test
2 $ rm -r folder1
3 USER@PC MINGW64 ~/Desktop/S175/test
4 $ rm -r folder2
5 USER@PC MINGW64 ~/Desktop/S175/test
6 $ rm info.txt
```

VCS - Version Control System

 Kai darbuojatės ir rašote dokumentus, darote juose pakeitimus, dažnai turite 10-20 dokumentų pvz., bakalaurinis.doc, bakalaurinis2.doc, bakalaurinis2019_01_02.doc, bakalaurinis2019_01_02(1).doc ir t.t.

Intro

- dar panašiai tiek pat .xls failų, kiek mažiau skirtingų .ppt failų
- Galų gale tai veda link chaoso!
- Todėl labai svarbu, ypač dirbant tu tekstiniais dokumentais (ne Word'iniais), pvz., R skriptais, LaTex failais, turėti vieną failą, bet būti išsisaugojus kartu visas jo ankstesnes formas ir galėti atstatyti ankstesnes jų versijas
- Bendradarbiaujant su kitais, taip pat svarbu galėti dalintis turimu dokumentu, kodu, leisti kitiems jį keisti ir galų galų integruoti pakeitimus į motininį failą



Trumpas įvadas į Git

"Git is a version-control system for tracking changes in computer files and coordinating work on those files among multiple people. It is primarily used for source-code management in software development, but it can be used to keep track of changes in any set of files. As a distributed revision-control system, it is aimed at speed, data integrity, and support for distributed, non-linear workflows"

https://en.wikipedia.org/wiki/Git

"Git is a free and open source distributed version control system designed to handle everything from small to very large projects with speed and efficiency"

https://git-scm.com/

- Sukurta Linux kurėjo Linus Torvalds
- Populiariausia VCS
- Viskas išsaugoma lokaliai
- GIT naudojamas naudojant CLI, nors Windows yra ir GUI
- Dowload GIT



Git pagrdiniai nustatymai

- Kiekvienas išsaugojimas bus susietas su išsaugotu "user.name" ir "user email"
- Tai reikia padaryti tik vieną kartą (dirbant su savo PC), arba pasikeisti kaskart prisėdus prie svetimo PC
- Bendradarbiaujant tai padeda atpažinti kas padarė kokius pakeitimus
- Konfikuruokite Git su savo vardu ir pavarde, bei universiteto email

```
$ git config —global user.name "Justas Mundeikis"
$ git config —global user.email justas.mundeikis@evaf.vu.lt
$ git config —global core.pager cat
$ git config —l
$ git config —global —l
```

GitHub

"GitHub is a web-based hosting service for version control using Git. It is mostly used for computer code. It offers all of the distributed version control and source code management (SCM) functionality of Git as well as adding its own features. It provides access control and several collaboration features such as bug tracking, feature requests, task management, and wikis for every project"

https://en.wikipedia.org/wiki/GitHub

- "push" ir "pull" tarp lokalių ir internetinių repozitorijų
- suteikia homepage vartotojo repozitorijoms
- GitHub atlieka back-up funkciją lokalioms repozitorijoms
- Leidžia bendradarbiauti, dalintis projektais, gerinti kitų kodą ir t.t.
- GitHub paskyros susikūrimas su VardasPavard (rekomenduotina) ir VU email

- Pirma pasitikriname ar esame .../\$175/test ir ar direktorija tuščia
- tada Inicializuojame git

```
USER@PC MINGW64 ~/Desktop/S175/test
  $ pwd
  /c/Users/USER/Desktop/S175/test
  USER@PC MINGW64 ~/Desktop/S175/test
  $ 1s −a
  ./ ../
  USER@PC MINGW64 ~/Desktop/S175/test
10 $ git init
11 Initialized empty Git repository in C:/Users/USER/Desktop/S175
      → /test/.git/
12
13 USEROPC MINGW64 ~/Desktop/S175/test (master)
14
  1s -a
15
  ./ ../ .git/
```

direktorijoje sukuriamas nematomas failas .git

Git = foto sesija


- Git daro "pasirinktos direktorijos nuotraukas"
- Inicializavimas, tai tarsi foto kambario pasirinkimas, kuriame gali būti daug "veikėjų"
- git add failname yra tarsi "veikėjo" užvedimas ant foto scenos
- git commit yra pačios nuotraukos darymas
- Tam kad nuotraukoje nebūtų tam tikrų asmenų galima naudoti sąrašą kuris slepiasi ".gitignore" faile



- Su komanda touch sukuriame faila readme.txt
- touch readme.txt
- Su Sublime atsidarome readme.txt.
- Jrašome "change1" ir išsaugome failą "Ctrl+S" (uždaryti Sublime nereikia)

Viskas turėtų atrodyti taip

12 pav.: Pirmas žingsnis



 Šis failas egzistuoja repo (nes jau sekame folderį o to kai parašėme komandą git init), tačiau nėra "sekamas"

```
USER@PC MINGW64 ~/Desktop/S175/test (master)
  $ git status
  On branch master
5
6
7
  No commits vet
  Untracked files:
     (use "git add <file >..." to include in what will be
         → committed)
9
10
          readme.txt
11
12 nothing added to commit but untracked files present (use "git

→ add " to track)
```

• Taigi failas readme.txt yra "untracked" kitaip tariant ne ant "scenos"

- Su git add readme.txt į keliame readme.txt į staging area
- patikriname statusą:

```
USER@PC MINGW64 ~/Desktop/S175/test (master)
git add readme.txt

USER@PC MINGW64 ~/Desktop/S175/test (master)
sgit status
On branch master

No commits yet

Changes to be committed:
   (use "git rm — cached < file > ..." to unstage)
new file: readme.txt
```

• Taigi failas readme.txt yra staged bet dar ne commited

- Su Sublime prirašome vieną eilutė "change2", tada Ctrl+S
- Ką rodo git status ?

```
USER@PC MINGW64 ~/Desktop/S175/test (master)
  $ git status
  On branch master
5
6
  No commits yet
  Changes to be committed:
8
    (use "git rm —cached <file >..." to unstage)
9
10
          new file: readme.txt
11
12
  Changes not staged for commit:
13
    (use "git add <file >..." to update what will be committed)
    (use "git checkout -- <file >..." to discard changes in
14
        → working directory)
15
16
           modified: readme.txt
```

- Norint išsaugoti naujausią versiją turime ją pervesti j staging area
- git add readme.txt

```
USER@PC MINGW64 ~/Desktop/S175/test (master)

git status

On branch master

No commits yet

Changes to be committed:
  (use "git rm —cached <file >..." to unstage)

new file: readme.txt
```

• "changes to be commited" reiškia, kad galime fotografuoti

norint perduoti failą repozitorijai (= fotografuoti)

• "working tree clean" reiškia, jog esame išsaugoję nuotrauk su visais naujausiais pakeitimais

Git commit -m "..."

- git commit -m "...."
- -m reiškia "message"
- Turime apie 72 ženklus, bet galima ir daugiau
- Aprašas turi būti aiškus, jog būtų prasmingas

13 pav.: https://m.xkcd.com/1296/

	COMMENT	DATE
Q	CREATED MAIN LOOP & TIMING CONTROL	14 HOURS AGO
9	ENABLED CONFIG FILE PARSING	9 HOURS AGO
φ	MISC BUGFIXES	5 HOURS AGO
φ	CODE ADDITIONS/EDITS	4 HOURS AGO
Q.	MORE CODE	4 HOURS AGO
þ	HERE HAVE CODE	4 HOURS AGO
Ιþ	ARAAAAA	3 HOURS AGO
6	ADKFJ5LKDFJ5DKLFJ	3 HOURS AGO
\dot \	MY HANDS ARE TYPING WORDS	2 HOURS AGO
þ	HAAAAAAAANDS	2 HOURS AGO

AS A PROJECT DRAGS ON, MY GIT COMMIT MESSAGES GET LESS AND LESS INFORMATIVE.

Toliau keičiame naudojamą failą:

- readme.txt prirašome "change3"
- git add readme.txt
- git commit -m "pridetas change 3"
- Taigi jau padarėme 2 *commit* (= 2 nuotraukas)

Git log

Norint žinoti kas, kada ir kaip keitė failą:

git log

```
USER@PC MINGW64 ~/Desktop/S175/test (master)
  $ git log
  commit 030210\,\mathrm{bb}490f45400a706ea69385e8fccc18c65a (HEAD ->
      → master)
  Author: Justas Mundeikis <mundeikis@gmx.de>
  Date: Thu Feb 14 13.28.03 2019 -0800
6
7
8
      pridetas change3
  commit ca5eddb5fa492038cb3c3d07f483542502bb1e90
10
  Author: Justas Mundeikis <mundeikis@gmx.de>
11
  Date: Thu Feb 14 13:24:27 2019 -0800
12
13
      sukurtas readme.txt, papildytas change1 ir change2
```

Git log -oneline

- Norint žinoti kas, kada ir kaip keitė failą, bet gauti mažiau info
- git log --oneline

```
USER@PC MINGW64 ~/Desktop/S175/test (master)

$ git log —oneline

3 030210b (HEAD —> master) pridetas change3
4 ca5eddb sukurtas readme.txt, papildytas change1 ir change2
```

- Dabar sukursime naują failą basic.R ir readme.txt pridėsime change4
- touch basic.R
- readme.txt įrašome "change4", išsaugome
- git status parodo, jog pakeistas *readme.txt* failas, ir untracked *basic.R* failas
- su komanda git add . staginame visus failus
- galimi kiti variantai : git add -A , git add -u (pastarasis naudojamas tik update'inti jau sekamus failus)
- tada git commit —m "pridedamas change4 ir sukuriamas failas basic.R"

- Kartais yra tam tikri failai, kurių nenorime sekti (pvz duomenys, nereikalingi LaTex failai ir t.t.)
- Sukuriame duomenų failą
- touch data.csv
- git status parodo failą kaip untracked
- todėl sukuriame failą touch .gitignore, kuriame galima surašyti failų pavadinimus, arba failų tipą/galūnes, kurių nenorime trackinti
- Sublime įrašome: *.csv
- * reiškia bet kokį pavadinimą, po kurio seka taškas ir csv, alternatyviai galima specifikuoti konkretų failą "data.csv"
- "git status" neberodo failo "data.csv" bet rodo ".gitignore", todėl staginame ir commitiname pakeitimus
- git add . ir git commit -m "sukurtas gitignore sarasas"

Git branch'inimas

- Bazinis scenarijus:
 - A kuria projektą, B nori prisidėti, tačiau ir A dirba tuo pat metu...
 - B atsiskelia atšaką (branch'ina) A projektą, padaro savo pakeitimus ir pateikia A juos sujungti
 - A peržiūri pakeitimus, priima/atmeta

Git branch'inimas

- git branch NewBranch sukuria naują atšaką pavadinimu NewBranch
- git checkout NewBranch išmeta iš "master" į NewBranch
- git checkout master visada sugrąžina atgal į master šaką

```
USER@PC MINGW64 ~/Desktop/s175/test (master)

$ git branch NewBranch

USER@PC MINGW64 ~/Desktop/s175/test (master)

$ git checkout NewBranch

Switched to branch 'NewBranch'
```

• dabar visi pakeitimai vyks tik šioje atšakoje ir nepaveiks master šakos

Darbas Git atšakoje

Tarkime dabar asmuo B darbuojasi NewBranch atšakoje tobulindamas projekta

- touch advanced.R
- notepad readme.txt jrašome papildomą eilutę "change5", tada Crtl+S
- staginam ir commitinam pakeitimus:
 - git add .
 - git commit —m "sukuriamas advanced.R ir pridedmas change5"
- sugrjžtame j master atšaka su git checkout master
- Rezultatas: trūksta advanced.R failo, readme.txt turi tik 4 jrašus!
- Norint sujungti naują atšaką j master git merge NewBranch

Git merge

- git merge NewBranch
- git log --oneline

```
USER@PC MINGW64 ~/Desktop/S175/test (master)
  $ git merge NewBranch
3 Updating b8940f7..407d27c
  Fast-forward
  advanced R
6 readme.txt | 3 ++-
7 2 files changed, 2 insertions (+), 1 deletion (-)
   create mode 100644 advanced R
9
10 USER@PC MINGW64 ~/Desktop/S175/test (master)
11 $ git log -- oneline
12 \mid 407 d27c (HEAD -> master, NewBranch) sukuriamas advanced.R ir
      → pridedmas change5
13 b8940f7 sukurtas gitignore sarasas
14 ebff561 pridedamas change4 ir sukuriamas failas basic.R
15 030210b pridetas change3
16 ca5eddb sukurtas readme.txt, papildytas change1 ir change2
```

Merge problemos

- Kartais nutinka taip, kad atšakoje esantys failai ne visai atitinka su master šakoje esančiais failais, todėl juos jungiant kyla problemų, kurias reikia pašalinti "ranka"
- master atšakoje readme.txt sukuriame eilutę "change5", Ctrl+S, stage'inam ir commit'iname
- Nueiname į atšaką *NewBranch* ir ten esančiame *readme.txt* sukuriame "change7", stage'inam ir commit'iname
- grįžtame į master atšaką git chekckout master
- ir bandome sujungti git merge NewBranch

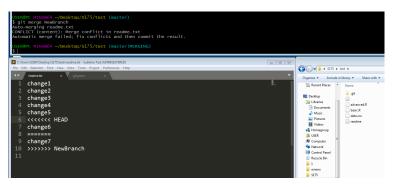
Merge problemos

 Git negalėjo automatiškai sutvarkyti failų (kaip pirmą kartą), nes dabar toje pačioje readme.txt failo vietoje vienur yra "change6" kitur "change7". Todėl atsidarome readme.txt failą ir tvarkome patys

Konfliktinio failo tvarkymas

Atsidarius readme.txt matome

14 pav.: Merge problema



- <<<<< HEAD yra tai kas yra aktyvioje atšakoje</p>
- >>>> NewBranch yra kas ateina iš sujungiamos atšakos
- atskirta =====

Konfliktinio failo tvarkymas

Sutvarkome faila, taip kaip norime

```
change1
change2
change3
change4
change5
change6
change7
```

- Išsaugome pakeitimus Ctrl+S, tada
- git commit -a -m "sujungtas failas is NewBranch bei pasalintas konfliktas
- git commit —a —m "..." galima naudoti, jeigu nėra sukurtų naujų failų
- Yra papildomų įrankių, kurie padeda atlikti merge'inimo darbus, nes dažniausiai konfliktų visada bus

Git atsatatymas 1

 Imituojame, jog dirbome ir sukūrėme gerą failą ir paskui jį papildėme blogu:

```
USER@PC MINGW64 ~/Desktop/S175/test (master)
  $ echo "sukuriamas geras failas" > svarbus.txt
  $ git add .
  $ git commit -m "sukurtas svarbus.txt"
  $ echo "12 nakties pridirbau nesamoniu" >> svarbus.txt
  $ git commit -a -m "pridirbta nesamone"
  $ git log -- oneline
8 | 78839b7 (HEAD -> master) pridirbta nesamone
9 9547650 sukurtas svarbus txt
10 2a982aa merge klaida panaikinta, change6 ir change7
11 26e6ae0 (NewBranch) sukurtas change7
12 8562e69 sukurtas change6
13 407d27c sukuriamas advanced.R ir pridedmas change5
14 b8940f7 sukurtas gitignore sarasas
15 ebff561 pridedamas change4 ir sukuriamas failas basic.R
16 030210b pridetas change3
17 ca5eddb sukurtas readme.txt, papildytas change1 ir change2
```

Git atsatatymas

- Norint susigražinti faila į praėjusią "gerą" būseną, reikia susirasti "blogo" commit hasha mano atveju (žr. viršuje) 78839b7
- git log ——oneline
- komanda git revert HASH atstato pasirinkta versija, versijos su "12 nakties..." nebėra!
- komanda git revert 78839b7
- po jvedimo atsiranda message langas (atitinka -m "...."), nes revert'inimas yra naujas commit

Perspėjimas

- Priklausomai nuo to, koks yra standartinis editorius priskirtas git, atsidaro arba Nano editorius, arba VIM editorius
- Kadangi VIM papildomas ir nebūtinai reikalingas apsunkinimas, šioje vietoje pridedu tik nuorod į youtube video (8min) kaip dirbti su VIM
- Mano siūlymas:
- git config ——global core.editor nano.exe
- tada revertinant atsidarys Nano, arba
- git config —global core.editor absadr kur vietoj absadr įrašomas sublime_text.exe su absoliučiu adresu
- PVZ
 git config —global core.editor /c/Users/USER/Download/sublime/sublime_text.ex.
- tada atsidaro Sublime langas!



Git atstatymas

15 pav.: Revert atidaro messge su nano

```
MINGW64:/c/Users/USER/Desktop/S175/test
                                                                                                ----X
 GNU nano 3.2
                           C:/Users/USER/Desktop/S175/test/.git/COMMIT_EDITMSG
Revert "pridirbta nesamone"
This reverts commit 78839b7cb6cba4b8fbc110b59311a6e94602adaf.
 On branch master
 Changes to be committed:
                   svarbus.txt
G Get Help AO Write Out AW Where Is AK Cut Text AJ Justify
             AR Read File A\ Replace
                                                                     A Go To Line M-F Redo
```

• Spaudžiame Crtl+X ir vėl atsiduriame normaliame Git



Git atstatymas

Tik jau blogojo įrašo Sublime neberodo

16 pav.: Po revert

```
MINGW64 ~/Desktop/S175/test (master)
 master f7d1fa1] Revert "pridirbta nesamone"
 1 file changed, 1 deletion(-)
C:\Users\USER\Desktop\S175\test\svarbus.txt - Sublime Text (UNREGISTERED)
File Edit Selection Find View Goto Tools Project Preferences Help
      sukuriamas geras failas
```

Git reset

- Atsargiai!
- Tarkime jus labai daug darbavotės, turite n commit padarę ir supratote, kad pirmas commit buvo geras, o po to viskas ne.
- git revert HASH palieka buvusias versijas, bet šiuo atveju, jos nebereikalingos
- git reset hard HASH komanda padaro hard-reset, t.y. resetina į pasirinktą commitą, tačiau ištrina viską, kas buvo daryta po to!
- revert'inti git reset ——hard HASH neįmanoma, priešingai nei paties revert.
- Taigi geriau su hard-reset nesižaist :D

Git branch ištrynimas

- Mums nebereikia NewBranch atšakos
- Kiek šakų turime patikrinti galima su git branch . * parodo kur esame
- Nereikalingą šaką ištrinti galime su komanda git branch –d Newbranch
 -d = delete

```
USER@PC MINGW64 ~/Desktop/S175/test (master)
git branch
NewBranch
* master

USER@PC MINGW64 ~/Desktop/S175/test (master)
git branch -d NewBranch
Deleted branch NewBranch (was 26e6ae0).

USER@PC MINGW64 ~/Desktop/S175/test (master)
gut
user@pc MINGW64 ~/Desktop/S175/test (master)
gut
user@pc MINGW64 ~/Desktop/S175/test (master)
spit branch
git branch
spit branch
spit branch
spit branch
spit waster
```


- norint žinoti, ar lokali repozitorija yra susieta su nuotoline repozitorija (pvz Github, Bitbucket ar pan)
- git remote
- Jeigu komanda neišmeta jokios informacijos, reiškia lokali repo nesusieta su nuotoline repo

- Nueiname kiekvienas į savo GitHub ir ten susikuriame repo:
 - pavadinimas: test
 - Description paliekam tučią
 - NE inicializuojame su README!!!!
- keliaujame į savo "test" direktoriją
- git remote add origin HTPPS
- git push u origin master


17 pav.: Nuotolinės repo kūrimas @GitHub: spaudžiam and + ir tada "New repository"



18 pav.: Nuotolinės repo kūrimas @GitHub: pavadinimas :test, Initialize paliekam tuščią ir spaudžiam "Creat repository"



19 pav.: Nuotolinės repo kūrimas @GitHub: šis langas pasako, kaip lokalinę repo sujungti su nuotoline...




- po git push reikės įrašyti savo email (GitHub) ir pop-up lange savo passwordą
- po git remote -v parodo daugiau info apie remote repo

```
$ git remote add origin https://github.com/justasmundeikis/
      \hookrightarrow test.git
2 | $ git remote -v
  origin https://github.com/justasmundeikis/test.git (fetch)
  origin https://github.com/justasmundeikis/test.git (push)
5 $ git push origin master
6 Username for 'https://github.com': vardas.pavarde@stud.vu.lt
  Enumerating objects: 32, done.
8 Counting objects: 100\% (32/32), done.
  Delta compression using up to 2 threads
10 Compressing objects: 100\% (21/21), done.
11 Writing objects: 100% (32/32), 2.55 KiB | 55.00 KiB/s, done.
12 Total 32 (delta 8), reused 0 (delta 0)
13 remote: Resolving deltas: 100% (8/8), done.
14 To https://github.com/justasmundeikis/test.git
   * [new branch] master -> master
15
```

2019 m. vasario 21 d.


20 pav.: Su F5 refresh'inus GitHub puslapį matome, jog vietinio folderio turinys visas perkeltas j GitHub



- Sveikinu su pirmu išsiuntimu savo darbo į internetą
- Suprantama, galima pirma sukurti repo @GitHub ir tada sukurtą repo klonuoti į savo PC tai, sekantis žingsnis
- Klonuoti galima ir "svetimas" repo


- Kiekvienas j savo GitHub paskyroje susikuriame repo:
 - Pavadinimas: test2
 - Description paliekam tuščią
 - inicializuojame su Readme.md


21 pav.: Sukuriama nauja repo "test2"



2019 m. vasario 21 d.

GitHub nusikopijuojame sukurtos repo HTTPS adresą





 Git Bash lange pakylame viena direktorija aukščiau, įsitikiname ar esame S175 folderyje ir klonuojame nusikopijuotą adresą:

```
USER@PC MINGW64 ~/Desktop/S175/test (master)

to cd ...

USER@PC MINGW64 ~/Desktop/S175

pwd

/c/Users/USER/Desktop/S175

USER@PC MINGW64 ~/Desktop/S175

USER@PC MINGW64 ~/Desktop/S175

git clone https://github.com/justasmundeikis/test2.git

Cloning into 'test2'...
remote: Enumerating objects: 3, done.
remote: Counting objects: 100% (3/3), done.
remote: Total 3 (delta 0), reused 0 (delta 0), pack-reused 0

Unpacking objects: 100% (3/3), done.
```

- Klonuotoje repo, sukursime failą, ir jį nusiųsime atgal į GitHub"
- pareikalavus įrašome github username ir userpassword
- GitHub atnaujiname (F5) ir voila, failas info.txt yra remote repozitorijoje (&&) apjungia dvi komandas vienoje eilutėje

```
USER@PC MINGW64 ~/Desktop/S175
  $ pwd
  /c/Users/USER/Desktop/S175
  USER@PC MINGW64 ~/Desktop/S175
  $ cd test2
  USER@PC MINGW64 ~/Desktop/S175
  $ echo "test2 klonavimas ir siuntimas i Github" >about.txt
10
  USER@PC MINGW64 ~/Desktop/S175
  $ git add . && git commit -m "sukurtas about.txt"
13
14 USER@PC MINGW64 ~/Desktop/S175
15 $ git push
```

- Sveikinu, sukūrėte GitHub repo
- Ją klovanote
- Pakeitėte vietinėje repo failus
- Ir juos pushinote į Github!
- Atnaujine Github, pamatysite savo naujai sukurtą failą!

- Dabar klonuokite dar viena folderj:
- Tačiau pirma jsitikinite, ar esate \$175 folderyje, jeigu ne, pereikite (žr sekanti skaidrė)
- git clone https://github.com/justasmundeikis/duomenu_analizes_ivadas.git
- Sveikinu, atsisiuntėte mano paskaitų medžiagą
- Norint žinoti ar nėra jokių paskaitos medžiagų atnaujinimo, galima nuėjus į patį folderį įrašyti komanda
- git pull



```
1 USER@PC MINGW64 ~/Desktop/S175
2 $ pwd
3 /c/Users/USER/Desktop/S175
 $ git clone https://github.com/justasmundeikis/

→ duomenu_analizes_ivadas.git

6 Cloning into 'duomenu_analizes_ivadas'...
7
8 USER@PC MINGW64 ~/Desktop/S175
9 $ 1s
0
 duomenu_analizes_ivadas/ test/ test2/
USER@PC MINGW64 ~/Desktop/S175
13 $ cd duomenu_analizes_ivadas /
4
1.5 USER@PC MINGW64 \sim/Desktop/S175/duomenu_analizes_ivadas (master)
6 s git pull
7 Already up to date.
```

Markdown sintaksė

- GitHub sukuriant repo, ją galima inicijuoti su readme.md
- .md reiškia, jog tai yra markdown formatas
- Markdown is a lightweight markup language with plain text formatting syntax. Its design allows it to be converted to many output formats, but the original tool by the same name only supports HTML. Markdown is often used to format readme files, for writing messages in online discussion forums, and to create rich text using a plain text editor. (https://en.wikipedia.org/wiki/Markdown)
- Labai trumpa pagalba dėl formatavimo: https://commonmark.org/help/
- Vėliau mes susipažinsime su RMarkdown



Google Scholar

- Viskas prasideda nuo daug skaitymo, tarkime aptinkate "The Economist" straipsnj apie "Brexit"
- Nusprendžiate kad esė tema galėtų būti "Kaip Brexit paveiks Lietuvos ekonomika"
- Dabar reikia eiti ieškoti moklsinių straipsnių, geriausiai tam tinka...
- https://scholar.google.lt/
- Funkcijos
 - Laikotarpis
 - Kurti jspėjjimą
 - citavimas
 - Cituoja
 - Visos versijos
 - AND OR
 - Išplėstinė paieška
- Dabar galime kartoti temos pavadinimo / klausimo epiciklą



Literatūra

- Apie duomenų analizė R.D. Peng & E.Matsui: "The Art of Data Science" 1-3 skyriai
- CLI patarčiau šią mokamąją medžiagą: Learn Enough Command Line to Be Dangerous
- Git patarčiau šią mokamąją medžiagą: Learn Enough Git to Be Dangerous
- Youtube: ieškant "Git Basics"

Namų darbai

- Namuose instaliuoti visas reikalingas programas (Git, Sublime)
- Pakartoti skaidrėse praeitus žingsnius
- Išspręsti Seminar 1 užduotis
- VU VMA įkelti savo Seminar 1 dokumento prašomas nuorodas
- Reguliariai pasitikrinti, ar nėra VMA įkeltų straipnsių skaitumui, jeigu yra, perskaityti, nes apie savaitinius skaitinius gali būti klausiama teste!!!